

بسمه تعالی

موضوع

تشخیص تقلب در کارت اعتباری:

یک مدل سازی واقع بینانه و یک استراتژی یادگیری جدید

درس

یادگیری ماشین

اساتید

دکتر یغمایی - شگری

گردآورنده

حوا عسکری

40011920006 : ش.د.

خلاصه

شناسایی تقلب در تراکنش‌های کارت اعتباری شاید یکی از بهترین بسترهای آزمایشی برای الگوریتم‌های هوش محاسباتی باشد. در واقع، این مشکل شامل تعدادی چالش مرتبط است، از جمله: تغییر مفهوم (عادات مشتریان تکامل می‌یابد و کلاهبرداران استراتژی‌های خود را در طول زمان تغییر می‌دهند)، عدم تعادل طبقه (تعداد معاملات واقعی بسیار بیشتر از تقلب‌ها) و تأخیر تأیید (فقط مجموعه کوچکی از تراکنش‌ها به موقع توسط بازرسان بررسی می‌شوند). با این حال، اکثریت قریب به اتفاق الگوریتم‌های یادگیری که برای کشف تقلب پیشنهاد شده‌اند، بر مفروضاتی تکیه می‌کنند که به سختی در یک سیستم تشخیص تقلب در دنیای واقعی (FDS) وجود دارند. این فقدان واقع‌گرایی به دو جنبه اصلی مربوط می‌شود:

1) روش و زمان‌بندی ارائه اطلاعات تحت نظارت

2) اقدامات مورد استفاده برای ارزیابی عملکرد کشف تقلب.

این مقاله سه سهم عمده دارد. اول، ما با کمک شریک صنعتی خود، رسمی کردن مشکل کشف تقلب را پیشنهاد می‌کنیم که به طور واقع بینانه شرایط عملیاتی FDS هایی را که هر روز جریان‌های عظیم تراکنش‌های کارت اعتباری را تجزیه و تحلیل می‌کنند، توصیف می‌کند. ما همچنین مناسب‌ترین معیارهای عملکردی را که برای اهداف کشف تقلب استفاده می‌شود، نشان می‌دهیم. دوم، ما یک استراتژی یادگیری جدید را طراحی و ارزیابی می‌کنیم که به طور موثر عدم تعادل کلاس، جابجایی مفهوم و تأخیر تأیید را بررسی می‌کند. سوم، در آزمایش‌های خود، تأثیر عدم تعادل طبقاتی و رانش مفهومی را در جریان داده‌های دنیای واقعی حاوی بیش از ۷۵ میلیون تراکنش، که در یک بازه زمانی سه ساله مجاز است، نشان می‌دهیم.

1-مقدمه

تشخیص تقلب کارت اعتباری یک مشکل مرتبط است که توجه جوامع یادگیری ماشینی و هوش محاسباتی را به خود جلب می‌کند، جایی که تعداد زیادی راه حل خودکار پیشنهاد شده است. در واقع، به نظر می‌رسد که این مشکل از منظر یادگیری چالش برانگیز باشد، زیرا در عین حال با عدم تعادل طبقاتی مشخص می‌شود، یعنی، تعداد تراکنش‌های واقعی بسیار بیشتر از تقلب‌ها است، و مفهوم منحرف می‌شود، یعنی تراکنش‌ها ممکن است ویژگی‌های آماری خود را در طول زمان تغییر دهند. با این حال، اینها تنها چالش‌هایی نیستند که مشکلات یادگیری را در یک سیستم کشف تقلب در دنیای واقعی (FDS) مشخص می‌کنند.

در یک FDS دنیای واقعی، جریان عظیم درخواست‌های پرداخت به سرعت توسط ابزارهای خودکار اسکن می‌شوند که تعیین می‌کنند کدام تراکنش‌ها باید مجاز باشند. طبقه بندی کننده‌ها معمولاً برای تجزیه و تحلیل

تمام تراکنش های مجاز و هشدار دادن به مشکوک ترین تراکنش ها استفاده می شوند. سپس هشدارها توسط بازرسان حرفه ای بازرسی می شوند که با دارندگان کارت تماس می گیرند تا ماهیت واقعی (اعم از واقعی یا تقلبی) هر تراکنش هشدار داده شده را تعیین کنند. با انجام این کار، محققین بازخوردی به سیستم در قالب تراکنش های برچسب گذاری شده ارائه می کنند که می تواند برای آموزش یا به روزرسانی طبقه بندی کننده استفاده شود تا عملکرد کشف تقلب در طول زمان حفظ شود (یا در نهایت بهبود یابد). اکثریت قریب به اتفاق تراکنش ها نمی توانند توسط محققین برای محدودیت های زمانی و هزینه ای آشکار تأیید شوند. این تراکنش ها بدون برچسب باقی می مانند تا زمانی که مشتریان تقلب ها را کشف و گزارش ندهند، یا تا زمانی که زمان کافی سپری شود به طوری که تراکنش های بدون مناقشه واقعی تلقی شوند.

بنابراین، در عمل، اکثر نمونه های نظارت شده با تاخیر قابل توجهی ارائه می شوند، مشکلی که به عنوان تأخیر تأیید شناخته می شود. تنها اطلاعات نظارت شده اخیری که برای به روزرسانی طبقه بندی کننده در دسترس است، از طریق تعامل هشدار-بازخورد ارائه می شود. اکثر مقالات در ادبیات، تأخیر تأیید و همچنین تعامل هشدار-بازخورد را نادیده می گیرند و به طور غیرواقعی فرض می کنند که برچسب هر تراکنش به طور منظم در دسترس FDS قرار می گیرد، به عنوان مثال، به صورت روزانه. با این حال، این جنبه ها باید هنگام طراحی یک FDS دنیای واقعی در نظر گرفته شوند، زیرا تأخیر تأیید در هنگام رخ دادن مفهوم مضر است، و تعامل هشدار-بازخورد مسئول نوعی سوگیری انتخاب نمونه (SSB) که تفاوت های بیشتری را بین توزیع داده های آموزش و آزمون است.

تفاوت مهم دیگر بین آنچه معمولاً در ادبیات انجام می شود و شرایط عملیاتی دنیای واقعی سیستم تشخیص تقلب (FDS) مربوط به اقدامات مورد استفاده برای ارزیابی عملکرد کشف تقلب است. اغلب، معیارهای رتبه بندی جهانی، مانند ناحیه زیر منحنی ROC (AUC)، یا معیارهای مبتنی بر هزینه استفاده می شوند، اما اینها این واقعیت را نادیده می گیرند که فقط تعداد کمی از هشدارها را می توان روزانه کنترل کرد، و شرکت ها به شدت نگران دقت هشدارهای تولید شده اند.

سهم اصلی این مقاله به شرح زیر است:

- 1) ما مکانیسم های تنظیم کننده یک FDS واقعی را توصیف می کنیم و یک مدل رسمی از مشکل طبقه بندی مفصل ارائه می کنیم تا در تشخیص تقلب مورد توجه قرار گیرد.
- 2) ما معیارهای عملکردی را معرفی می کنیم که در یک FDS واقعی در نظر گرفته می شوند.
- 3) در این مدل صحیح و واقع بینانه، ما یک استراتژی یادگیری موثر برای پرداختن به چالش های فوق، از جمله تأخیر تأیید و تعامل هشدار-بازخورد پیشنهاد می کنیم. این استراتژی یادگیری بر روی تعداد زیادی از تراکنش های کارت اعتباری آزمایش شده است.

این مقاله به شرح زیر تنظیم شده است. ما ابتدا شرایط عملیاتی یک FDS دنیای واقعی را در بخش 2 به تفصیل شرح می‌دهیم، و سپس در بخش 3 مشکل آشکارسازی تقلب را مدل می‌کنیم و مناسب‌ترین معیارهای عملکرد را ارائه می‌کنیم. به‌ویژه، ما فکر می‌کنیم که مناسب‌ترین ارزیابی تعداد تراکنش‌های (یا کارت‌های) جعلی کشف‌شده بر روی حداکثر تعداد تراکنش‌ها (یا کارت‌هایی) است که بازرسان می‌توانند بررسی کنند. چالش‌های اصلی که هنگام آموزش یک طبقه‌بندی‌کننده برای اهداف کشف تقلب مطرح می‌شوند، سپس در بخش 4 مورد بحث قرار می‌گیرند. بخش 5 استراتژی یادگیری پیشنهادی را معرفی می‌کند، که شامل آموزش جداگانه طبقه‌بندی‌کننده‌های مختلف از بازخوردها و نمونه‌های نظارت شده با تأخیر، و سپس جمع‌آوری پیش‌بینی‌های آن‌ها است. این استراتژی، با الهام از ماهیت متفاوت بازخوردها و نمونه‌های نظارت شده با تأخیر، به ویژه در FDS با استفاده از پنجره کشویی یا مجموعه طبقه‌بندی‌کننده‌ها مؤثر است. ما ادعاهای خود را در آزمایش‌ها (بخش 6) روی بیش از 75 میلیون تراکنش کارت اعتباری تجارت الکترونیکی که طی سه سال به دست آمده‌اند، تأیید می‌کنیم، که همچنین برای مشاهده تأثیر عدم تعادل طبقاتی و تغییر مفهوم در جریان‌های تراکنش در دنیای واقعی تجزیه و تحلیل می‌شوند.

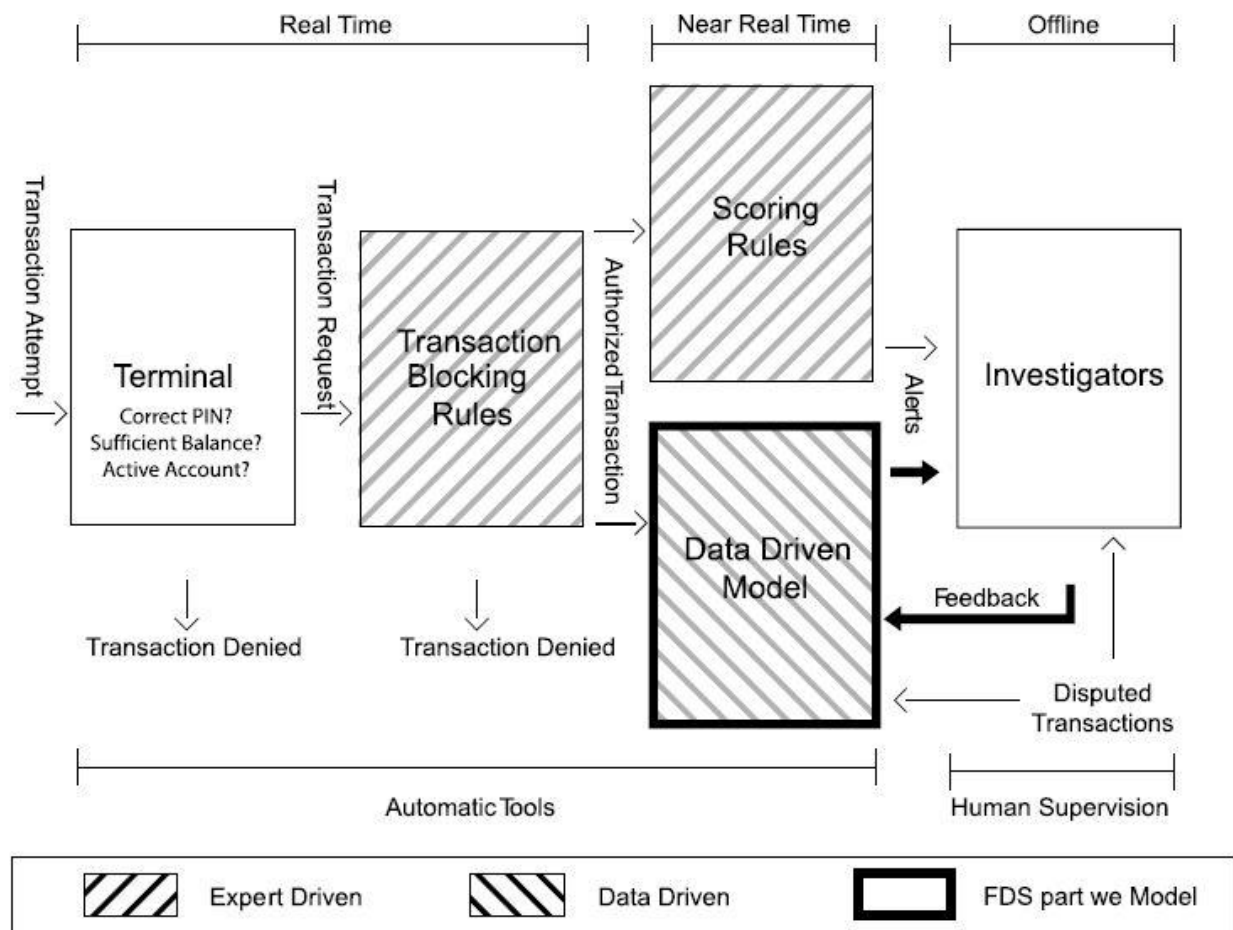
کار ما بر اساس [1] است، که به طور قابل توجهی با توصیف جزئیات شرایط عملیاتی در دنیای واقعی یک FDS و با تجزیه و تحلیل SSB معرفی شده توسط تعامل هشدار-بازخورد گسترش می‌یابد. علاوه بر این، بخش تجربی با ارائه تجزیه و تحلیل اضافی در دو مجموعه داده بزرگ تا حد زیادی به روز و تکمیل شده است.

2-FDS دنیای واقعی

در اینجا ما ویژگی‌های اصلی و شرایط عملیاتی یک FDS در دنیای واقعی را شرح می‌دهیم، که با الهام از موردی که به طور معمول توسط شریک صنعتی ما استفاده می‌شود، الهام گرفته شده است. شکل 1 پنج لایه کنترل را نشان می‌دهد که معمولاً در یک FDS استفاده می‌شود:

- (1) ترمینال (2) قوانین مسدود کردن معاملات (3) قوانین امتیازدهی (4) مدل داده محور (DDM) (5) محققین

لایه‌های (1-4) به طور کامل کنترل‌های خودکار را اجرا می‌کنند، در حالی که لایه 5 تنها لایه ای است که نیاز به دخالت انسان دارد.



شکل 1: طرحی که لایه های کنترل را در یک FDS نشان می دهد. تمرکز ما عمدتاً بر روی DDM و تعامل هشدار-بازخورد است، که نحوه ارائه نمونه های نظارت شده اخیر را تنظیم می کند.

A. لایه های کنترل در یک FDS

1) **ترمینال:** ترمینال اولین لایه کنترلی را در یک FDS نشان می دهد و بررسی های امنیتی معمولی را روی تمام درخواست های پرداخت انجام می دهد. بررسی های امنیتی شامل کنترل کد پین (فقط در مورد کارتهایی که دارای تراشه هستند امکان پذیر است)، تعداد تلاش ها، وضعیت کارت (فعال یا مسدود شده)، موجودی موجود و محدودیت هزینه ها. در صورت تراکنش های آنلاین، این عملیات باید به صورت بلادرنگ انجام شود (پاسخ باید در چند میلی ثانیه ارائه شود)، که طی آن ترمینال از سرور شرکت صادرکننده کارت استعلام می گیرد. درخواست هایی که از هیچ یک از این کنترل ها عبور نمی کنند رد می شوند، در حالی که بقیه به درخواست های تراکنش تبدیل می شوند که توسط لایه دوم کنترل پردازش می شوند.

(2) قوانین مسدود کردن تراکنش: قوانین مسدودکننده تراکنش عبارت‌اند از اگر-آنگاه (else-)

مسدود کردن درخواست‌های تراکنش که به وضوح به عنوان کلاهبرداری درک می‌شوند. این قوانین از اندک اطلاعات موجود در هنگام درخواست پرداخت، بدون تجزیه و تحلیل سوابق تاریخی یا مشخصات دارنده کارت استفاده می‌کنند. یک مثال از قانون مسدود کردن می‌تواند این باشد: «اگر تراکنش‌های اینترنتی و وب‌سایت ناامن، آنگاه تراکنش را رد کنید». در عمل، چندین قانون مسدود کردن تراکنش به طور همزمان اجرا می‌شوند و تراکنش‌هایی که هر یک از این قوانین را اجرا می‌کنند مسدود می‌شوند (اگرچه کارت‌ها غیرفعال نمی‌شوند). قوانین مسدودسازی تراکنش‌ها به صورت دستی توسط محقق طراحی می‌شوند و به این ترتیب، اجزای متخصص محور FDS هستند. برای تضمین عملیات بلادرنگ و جلوگیری از مسدود کردن بسیاری از تراکنش‌های واقعی، قوانین مسدود کردن باید: 1) سریع محاسبه شوند و 2) بسیار دقیق باشند، یعنی هشدارهای نادرست بسیار کمی ایجاد کنند.

تمام تراکنش‌هایی که قوانین مسدودسازی را پشت سر می‌گذارند در نهایت مجاز هستند. با این حال، فعالیت کشف تقلب پس از غنی‌سازی داده‌های تراکنش با ویژگی‌های انبوهی که برای مقایسه خرید فعلی با خریدهای قبلی و نمایه دارنده کارت استفاده می‌شود، ادامه می‌یابد. این ویژگی‌های جمع‌آوری شده شامل، برای مثال، میانگین هزینه، میانگین تعداد تراکنش‌ها در همان روز، یا مکان خریدهای قبلی است. فرآیند محاسبه ویژگی‌های انباشته به عنوان افزایش ویژگی نامیده می‌شود و در بخش B توضیح داده شده است. ویژگی‌های افزوده شده و داده‌های تراکنش فعلی در یک بردار ویژگی انباشته می‌شوند که قرار است برای تعیین تقلبی یا واقعی بودن تراکنش مجاز آموزنده باشد. لایه‌های زیر از FDS بر روی این بردار ویژگی عمل می‌کنند.

(3) قوانین امتیازدهی: قوانین امتیازدهی نیز مدل‌های متخصص محور هستند که به صورت عبارات

if-then – else بیان می‌شوند. با این حال، اینها بر روی بردارهای ویژگی عمل می‌کنند و به هر تراکنش مجاز امتیازی اختصاص می‌دهند: هر چه امتیاز بزرگتر باشد، احتمال تقلب تراکنش بیشتر است. قوانین امتیازدهی به صورت دستی توسط محققین طراحی می‌شوند که به طور دلخواه نمرات مرتبط خود را مشخص می‌کنند. یک مثال از قانون امتیازدهی می‌تواند این باشد که "اگر تراکنش قبلی در قاره ای متفاوت و کمتر از 1 ساعت از تراکنش قبلی باشد، امتیاز تقلب = 0.95". متأسفانه، قوانین امتیازدهی فقط می‌توانند استراتژی‌های متقلبان‌های را شناسایی کنند که قبلاً توسط محققین کشف شده‌اند و الگوهایی را نشان می‌دهند که اجزای کمی از بردارهای ویژگی را شامل می‌شوند.

علاوه بر این، قوانین امتیازدهی نسبتاً ذهنی هستند، زیرا کارشناسان مختلف قوانین متفاوتی را طراحی می کنند.

(4) مدل داده محور (DDM): این لایه صرفاً مبتنی بر داده است و از یک طبقه بندی کننده یا مدل آماری دیگری برای تخمین احتمال تقلب بودن هر بردار ویژگی استفاده می کند. این احتمال به عنوان امتیاز تقلب مرتبط با تراکنش های مجاز استفاده می شود. بنابراین، DDM از مجموعه ای از تراکنش های برچسب گذاری شده آموزش داده می شود و نمی تواند توسط محققین تفسیر یا به صورت دستی اصلاح شود. انتظار می رود که یک DDM موثر الگوهای تقلبی را با تجزیه و تحلیل همزمان چندین مؤلفه بردار ویژگی، احتمالاً از طریق عبارات غیرخطی، شناسایی کند. بنابراین، از DDM انتظار می رود که تقلب ها را طبق قوانینی که فراتر از تجربه محقق است، پیدا کند و لزوماً با قوانین قابل تفسیر مطابقت ندارد.

این مقاله بر این مؤلفه از FDS متمرکز است و یک استراتژی برای طراحی، آموزش و به روز رسانی DDM برای بهبود عملکرد تشخیص تقلب پیشنهاد می کند. تراکنش های مرتبط با بردارهای ویژگی که امتیاز تقلب زیادی را دریافت کرده اند یا احتمال کلاهبرداری بالایی دارند، هشدارهایی را ایجاد می کنند. تنها تعداد محدودی از تراکنش های هشدار داده شده به بازرسان گزارش می شوند که لایه نهایی کنترل را نشان می دهند.

(5) محققین: محققین حرفه ای با تجربه در تجزیه و تحلیل تراکنش های کارت اعتباری هستند و مسئولیت لایه های متخصص محور FDS را بر عهده دارند. به طور خاص، بازرسان قوانین مسدود کردن تراکنش و امتیازدهی را طراحی می کنند.

بازرسان همچنین مسئول کنترل هشدارهای اعلام شده توسط قوانین امتیازدهی و DDM هستند تا تعیین کنند که آیا این هشدارها با تقلب یا هشدارهای نادرست مطابقت دارند. به طور خاص، آنها تمام تراکنش های هشدار داده شده را در یک ابزار مدیریت پرونده، که در آن تمام اطلاعات مربوط به تراکنش، از جمله امتیازات/احتمالات اختصاص داده شده، گزارش می شود، تجسم می کنند، که در عمل نشان می دهد که هر تراکنش چقدر مخاطره آمیز است. بازرسان با دارندگان کارت تماس می گیرند و پس از تأیید، برچسب "اصیل" یا "تقلب" را به تراکنش هشدار داده شده اختصاص می دهند و این اطلاعات را به FDS برمی گردانند. در ادامه، ما به این تراکنش های برچسب گذاری شده به عنوان بازخورد اشاره می کنیم و از عبارت تعامل هشدار-بازخورد برای توصیف این مکانیسم استفاده می کنیم که اطلاعات نظارت شده را در یک FDS دنیای واقعی به دست می دهد.

هر کارتی که قربانی کلاهبرداری شود بلافاصله مسدود می شود تا از فعالیت های متقلبانه بیشتر جلوگیری شود. به طور معمول، بازرسان تمام تراکنش های اخیر را از یک کارت در معرض خطر بررسی می کنند، به این معنی که هر کلاهبرداری شناسایی شده به طور بالقوه می تواند بیش از یک بازخورد ایجاد کند، که لزوماً با هشدارها یا کلاهبرداری ها مطابقت ندارد. در یک FDS دنیای واقعی، محققین فقط می توانند چند هشدار را در روز بررسی کنند زیرا این فرآیند می تواند طولانی و خسته کننده باشد. بنابراین، هدف اولیه یک DDM، بازگرداندن هشدارهای دقیق است، زیرا زمانی که هشدارهای نادرست بیش از حد گزارش می شود، محققان ممکن است هشدارهای بیشتر را نادیده بگیرند.

B. تقویت ویژگی ها

هر درخواست تراکنش با چند متغیر مانند شناسه تاجر، شناسه دارنده کارت، مبلغ خرید، تاریخ و زمان توصیف می شود. تمام درخواست های تراکنش هایی که قوانین مسدود کردن را تصویب می کنند در یک پایگاه داده حاوی تمام تراکنش های مجاز اخیر، جایی که فرآیند افزایش ویژگی ها شروع می شود، وارد می شوند. در طول افزایش ویژگی، مجموعه خاصی از ویژگی های انبوه مرتبط با هر تراکنش مجاز محاسبه می شود تا اطلاعات بیشتری در مورد خرید ارائه کند و کلاهبرداری ها را از تراکنش های واقعی تشخیص دهد. نمونه هایی از ویژگی های جمع آوری شده عبارتند از میانگین هزینه های مشتری در هر هفته/ماه، میانگین تعداد تراکنش ها در روز یا در همان فروشگاه، میانگین مبلغ تراکنش، و مکان آخرین خریدها. Van Vlasselaer و همکاران نشان می دهد که ویژگی های اطلاعاتی اضافی را می توان از شبکه های اجتماعی که دارندگان کارت را با بازرگانان/فروشگاه ها متصل می کند استخراج کرد. ویژگی های جمع آوری شده بسیار آموزنده هستند، زیرا فعالیت های اخیر دارنده کارت را خلاصه می کنند. بنابراین، آنها به تراکنش هایی هشدار می دهند که به خودی خود مشکوک نیستند اما ممکن است در مقایسه با عادات خرید دارنده کارت خاص غیرعادی باشند. افزایش ویژگی ها می تواند از نظر محاسباتی گران باشد، و ویژگی های انبوه اغلب برای هر دارنده کارت بر اساس تراکنش های تاریخی، به صورت آفلاین محاسبه می شوند. ویژگی های تجمیع شده با داده های تراکنش در بردار ویژگی انباشته می شوند.

C. اطلاعات نظارت شده

بازخوردهای محققین جدیدترین اطلاعات نظارت شده ای است که در اختیار FDS قرار گرفته است، اما تنها بخش کوچکی از تراکنش های پردازش شده هر روز را نشان می دهد. تراکنش های برچسب دار اضافی توسط دارندگان کارت ارائه می شوند که مستقیماً با تراکنش های غیرمجاز مخالفت می کنند. زمان تراکنش های مورد مناقشه می تواند به طور قابل توجهی متفاوت باشد، زیرا دارندگان کارت هنگام بررسی رونوشت

کارت اعتباری ارسال شده توسط بانک، عادت های متفاوتی دارند. علاوه بر این، بررسی تراکنش های مورد مناقشه مستلزم برخی رویه های اداری لازم است که ممکن است تاخیرهای قابل توجهی ایجاد کند. تمام تراکنش های دیگر بدون برچسب باقی می ماند: این تراکنش ها می توانند تراکنش های واقعی یا کلاهبرداری هایی باشند که توسط FDS نادیده گرفته شده و توسط دارندگان کارت نادیده گرفته شده اند. با این حال، پس از گذشت تعداد معینی از روزهای بدون اختلاف دارنده کارت، تمام تراکنش های گزارش نشده به طور پیش فرض واقعی در نظر گرفته می شوند و در مجموعه آموزشی DDM درج می شوند. به طور کلی، دو نوع اطلاعات نظارت شده وجود دارد: 1) بازخوردهای ارائه شده توسط محققین که تعداد آنها محدود است اما به تراکنش های اخیر اشاره دارد و 2) تراکنش های نظارت شده با تأخیر که اکثریت قریب به اتفاق آن برچسب ها پس از چند روز در دسترس قرار می گیرند (به عنوان مثال، یک ماه). این مورد اخیر شامل معاملات مورد مناقشه و غیرمنزاعه می شود.

D. به روزرسانی سیستم

رفتار خرج کردن مشتریان تکامل می یابد و کلاهبرداران به طور مداوم حملات جدیدی را طراحی می کنند و بنابراین استراتژی های آنها نیز در طول زمان تغییر می کند. سپس لازم است به طور مداوم FDS را به روز کنید تا عملکرد رضایت بخش را تضمین کنید. سیستم های متخصص محور مرتباً توسط محققینی به روزرسانی می شوند که قوانین موقت (مسدود کردن تراکنش یا امتیازدهی) را برای مقابله با شروع فعالیت های جعلی جدید اضافه می کنند و آن قوانینی را که در معرض هشدارهای نادرست زیاد هستند حذف می کنند. با این حال، محققین نمی توانند DDM را تغییر دهند، زیرا قابل تفسیر نیست و فقط می تواند بر اساس اطلاعات نظارت شده اخیر، همانطور که در شکل 1 نشان داده شده است، به روز شود (به عنوان مثال، دوباره آموزش داده شود). بنابراین، اگرچه محققین به طور پیوسته در طول روز بازخورد ارائه می کنند، طبقه بندی کننده معمولاً فقط یک بار به روز می شود/بازآموز می شود، به ویژه در پایان روز، زمانی که تعداد کافی بازخورد در دسترس باشد.

3-فرمول مسأله

در اینجا، ما مشکل طبقه بندی را مدل سازی می کنیم تا در یک FDS دنیای واقعی به آن پرداخته شود، و یک توصیف رسمی از تعامل هشدار-بازخورد و ارائه معیارهای عملکرد مناسب ارائه می کنیم. استراتژی یادگیری پیشنهادی (بخش پنجم) و آزمایش های ما (بخش ششم) بر اساس این مدل ساخته شده اند.

اجازه دهید x_i بردار ویژگی مرتبط با آمین تراکنش مجاز را نشان دهد و $y_i \in \{+, -\}$ کلاس مربوطه باشد، جایی که $+$ نشان دهنده یک تقلب و $-$ یک تراکنش واقعی است. برای مقابله با ماهیت متغیر زمانی جریان تراکنش، یک طبقه بندی کننده K هر روز به روز می شود (یا تازه آموزش می بیند). به طور خاص، طبقه بندی کننده ای را که تا روز $t - 1$ در دسترس است، با \mathcal{K}_{t-1} نشان می دهیم. طبقه بندی کننده \mathcal{K}_{t-1} سپس برای پردازش مجموعه ای از تراکنش های T_t که در روز t مجاز شده اند استفاده می شود. ما با $\mathcal{P}_{\mathcal{K}_{t-1}}(+|x_i)$ قسمت عقبی \mathcal{K}_{t-1} را نشان می دهیم، یعنی احتمال تقلب بودن x_i مطابق \mathcal{K}_{t-1} . محققین فقط چند تراکنش پرخطر را بررسی می کنند. بنابراین، ما هشدارها را به عنوان K -ریسک ترین معاملات، یعنی

$$A_t = \{x_i \in T_t \text{ s.t. } r(x_i) \leq k\} \quad (1)$$

جایی که $r(x_i) \in \{1, \dots, |T_t|\}$ رتبه x_i با توجه به $\mathcal{P}_{\mathcal{K}_t}(+|x_i)$ است و $k > 0$ حداکثر تعداد هشدارهایی است که می تواند توسط محققین بررسی شود. همانطور که در بخش 2-A.5 بحث شد، محققین با دارندگان کارت تماس می گیرند و نمونه های نظارت شده را در قالب بازخورد در اختیار FDS قرار می دهند. به طور خاص، بازخوردها شامل تمام تراکنش های اخیر از کارت های کنترل شده است که ما آن ها را به عنوان مدل سازی می کنیم

$$F_t = \{(x_i, y_i) \text{ s.t. } x_i \text{ is from cards}(A_t)\} \quad (2)$$

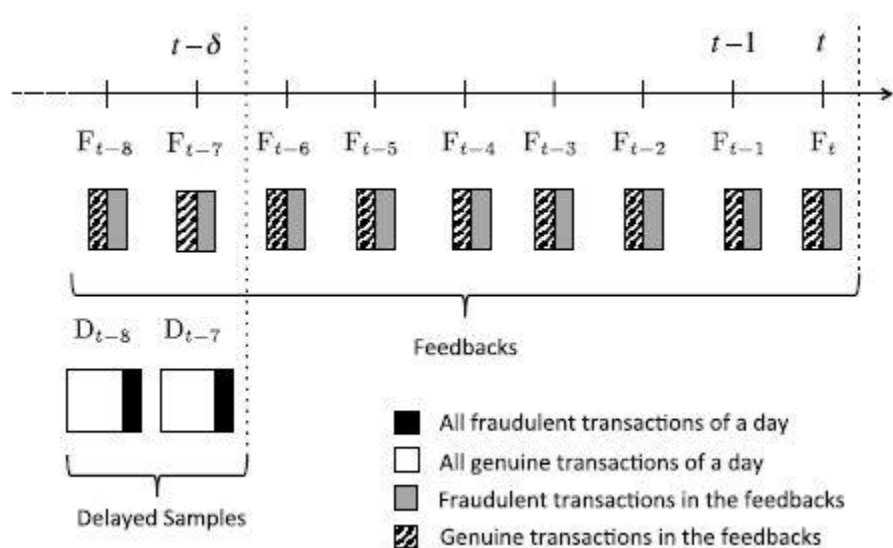
که در آن $\text{cards}(A_t)$ مجموعه کارتهایی را نشان می دهد که حداقل تراکنش در A_t دارند. تعداد بازخوردها، یعنی $|\mathcal{F}_t|$ ، به تعداد تراکنش های مرتبط با k کارت های کنترل شده بستگی دارد.

پس از تأخیر مشخصی در تأیید، برچسب های همه تراکنش ها در اختیار FDS قرار می گیرد، زیرا همانطور که در بخش 2-C بحث شد، تراکنش های بدون مناقشه واقعی در نظر گرفته می شوند. برای سادگی، ما تأخیر تأیید ثابت δ روز را فرض می کنیم، به طوری که در روز t ، برچسب های تمام تراکنش های مجاز در روز $t - \delta$ ارائه می شود. ما به این نمونه های تحت نظارت تأخیری اشاره می کنیم

$$D_{t-\delta} = \{(x_i, y_i), \quad x_i \in T_{t-\delta}\}. \quad (3)$$

توجه داشته باشید که $F_{t-\delta} \subset D_{t-\delta}$ از آنجایی که تراکنش ها در روز $t - \delta$ آشکارا شامل مواردی هستند که هشدار داده شده اند. شکل 2 انواع مختلف اطلاعات تحت نظارت موجود در یک FDS را نشان می دهد.

شایان ذکر است که علیرغم اینکه توضیحات رسمی ما شامل چندین جنبه و جزئیات است که تاکنون در ادبیات کشف تقلب نادیده گرفته شده است، این مدل همچنان یک مدل ساده شده است. در واقع، هشدارها در یک FDS دنیای واقعی معمولاً به صورت آنلاین هنگام پردازش تراکنش‌ها، بدون نیاز به رتبه‌بندی همه تراکنش‌ها در T_t ، مطرح می‌شوند. به طور مشابه، زوج‌های تحت نظارت تأخیر یک‌باره نمی‌آیند، زیرا هر تراکنش مورد اختلاف ممکن است کمتر (یا احتمالاً بیشتر) از δ روز طول بکشد. با وجود این، ما فکر می‌کنیم که فرمول‌بندی ما جنبه‌های یک FDS دنیای واقعی را در نظر می‌گیرد که از منظر یادگیری مهم‌ترین آنها هستند، که شامل هشدارها، تعامل تغییر بازخورد و تأخیر تأیید می‌شود. ما همچنین اظهار می‌کنیم که در اصل، از آنجایی که طبقه‌بندی‌کننده هر بردار ویژگی x_i را به طور مستقل تجزیه و تحلیل می‌کند، به کارت‌هایی که چندین تراکنش مخاطره‌آمیز دریافت می‌کنند هشدار نمی‌دهد تا زمانی که هر یک از اینها در مخزن هشدارها وارد شود (1). با این حال، این موقعیت‌ها به‌ویژه برای محققین مرتبط هستند و می‌توانند با قوانین امتیازدهی مناسب یا افزایش ویژگی‌ها کنترل شوند، به عنوان مثال، مؤلفه‌ای اضافه شود که امتیازات تراکنش‌های اخیر را پیگیری می‌کند.



شکل 2: نمونه‌های نظارت شده موجود در پایان روز t شامل: (1) بازخورد $[F^{(t)}]$ و (2) زوج‌های تاخیری $[D^{(t)}]$ قبل از $t - \delta$ روز رخ داده‌اند. در این نمودار، ما $\delta = 7$ را فرض کرده‌ایم. الگوها برچسب‌های مختلف را نشان می‌دهند، و اندازه این مناطق نشان‌دهنده نسبت‌های کلاس متعادل/نامتعادل است.

عملکرد تشخیص تقلب را می‌توان به راحتی از نظر دقت هشدار $P_k(t)$ ارزیابی کرد که به صورت تعریف می‌شود

$$P_k(t) = \frac{|TP_k(t)|}{k} \quad (4)$$

جایی که $\{xi \in At, yi = +\}$ بطوری که $TPk(t) = \{(xi, yi)\}$. بنابراین، $P_k(t)$ نسبت تقلب ها در هشدارها است. اگرچه طبقه‌بندی‌کننده به‌طور مستقل هر بردار ویژگی را پردازش می‌کند، اما دقت هشدار به‌جای ترائکشن‌های مجاز، به‌طور واقعی‌تر از نظر کارت‌ها اندازه‌گیری می‌شود. در واقع، چندین ترائکشن در A_t از یک کارت باید به عنوان یک هشدار واحد در نظر گرفته شود، زیرا محققان هنگام تماس با دارندگان کارت، تمام ترائکشن‌های اخیر را بررسی می‌کنند. این بدان معناست که k به حداکثر تعداد کارتهایی که محققین می‌توانند کنترل کنند بستگی دارد. در این زمینه، اندازه‌گیری عملکرد شناسایی در سطح کارت آموزنده‌تر است، به‌طوری که چندین ترائکشن متقابلانه از یک کارت به عنوان یک تشخیص صحیح منفرد محسوب می‌شود. بنابراین، ما CP_k ، دقت کارت، را به عنوان نسبت کارت‌های تقلبی شناسایی شده در کارت‌های k که توسط محققین کنترل می‌شود، معرفی می‌کنیم.

$$CP_k(t) = \frac{|C_t^+|}{k} \quad (5)$$

که در آن C_t^+ مجموعه‌ای از کارت‌های تقلبی را نشان می‌دهد که به درستی در روز t شناسایی شده‌اند، یعنی کارت‌های تقلبی که حداقل یک هشدار را گزارش کرده‌اند. برای محاسبه صحیح روزهایی که کمتر از k کارت تقلبی هستند، $CP_k(t)$ نرمال شده را به عنوان

$$NCP_k(t) = \frac{CP_k(t)}{\Gamma(t)} \quad \text{with} \quad \Gamma(t) = \begin{cases} 1 & \text{if } \gamma_t \geq k \\ \frac{\gamma_t}{k} & \text{if } \gamma_t < k \end{cases} \quad (6)$$

که در آن $\Gamma(t)$ حداکثر مقدار $CP_k(t)$ و γ_t تعداد کارت‌های تقلبی در روز t است. از (6)، داریم که $NCP_k(t)$ مقادیری را در محدوده $[0, 1]$ می‌گیرد، در حالی که $CP_k(t)$ وقتی $\gamma_t > k$ در $[0, 1]$ و در غیر این صورت در $\{(\gamma_t/k), 0\}$ است. به عنوان مثال، اگر در روز t ، 40 کارت تقلبی ($|C_t^+| = 40$) از 100 کارت بررسی شده توسط محققین را به درستی شناسایی کرده باشیم، و تعداد کلی کارت‌های تقلبی 50 باشد ($\gamma_t = 50$)، پس $CP_k(t) = 0.4$ در حالی که $NCP_k(t) = \frac{0.4}{0.5} = 0.8$.

توجه داشته باشید که از آنجایی که $\Gamma(t)$ به طبقه‌بندی‌کننده خاص \mathcal{K}_{t-1} اتخاذ شده بستگی ندارد، وقتی الگوریتم "A" از الگوریتم "B" از نظر CP_k بهتر است، "A" نیز از نظر "B" بهتر است. NCP_k علاوه بر این، به دلیل تأخیر تأیید، تعداد کارت‌های تقلبی در روز t (یعنی γ_t) فقط پس از چند روز قابل محاسبه است و بنابراین NCP_k نمی‌تواند در زمان واقعی محاسبه شود. بنابراین، توصیه می‌کنیم از CP_k برای ارزیابی عملکرد

در حال اجرا استفاده کنید، در حالی که از NCP_k برای آزمایش برگشتی استفاده کنید، به عنوان مثال، هنگام آزمایش پیکربندی‌های مختلف FDS، مانند بخش 6-F.

4- کار مرتبط

A. رویکردهای داده محور در تشخیص تقلب در کارت اعتباری

هر دو روش نظارت شده و بدون نظارت برای اهداف کشف کلاهبرداری کارت اعتباری پیشنهاد شده است. روش‌های نظارت نشده شامل تکنیک‌های تشخیص نابه‌هنجاری است که هر معامله‌ای را که با اکثریت مطابقت ندارد، تقلب در نظر می‌گیرد. قابل توجه است که یک DDM بدون نظارت در یک FDS می‌تواند مستقیماً از تراکنش‌های بدون برچسب پیکربندی شود. یک روش معروف، تجزیه و تحلیل گروه هم‌تا است که مشتریان را بر اساس مشخصات آنها خوشه بندی می‌کند و کلاهبرداری‌ها را به عنوان تراکنش‌هایی که از رفتار معمول دارنده کارت خارج می‌شوند، شناسایی می‌کند. رفتار معمولی دارنده کارت نیز با استفاده از نقشه‌های خودسازماندهی مدل شده است.

روش‌های نظارت شده جزء محبوب‌ترین روش‌ها در کشف تقلب هستند و از تراکنش‌های برچسب‌گذاری شده برای آموزش یک طبقه‌بندی کننده استفاده می‌کنند. تقلب‌ها با طبقه بندی بردارهای ویژگی تراکنش‌های مجاز یا احتمالاً با تجزیه و تحلیل قسمت‌های پسین طبقه بندی کننده شناسایی می‌شوند. چندین الگوریتم طبقه‌بندی بر روی تراکنش‌های کارت اعتباری برای شناسایی تقلب‌ها آزمایش شده‌اند، از جمله قوانین انجمن رگرسیون لجستیک شبکه‌های عصبی که از ماشین‌های برداری پشتیبانی می‌کنند که تجزیه و تحلیل تفکیک فیش و درخت‌های تصمیم را اصلاح کرده‌اند. چندین مطالعه جنگل تصادفی (RF) را برای دستیابی به بهترین عملکرد گزارش کرده‌اند: این یکی از دلایلی است که ما RF را در آزمایشات خود به کار می‌گیریم.

B. معیار عملکرد برای کشف تقلب

معیار عملکرد معمولی برای مشکلات کشف تقلب، AUC است. AUC را می‌توان با استفاده از آمار Mann-Whitney تخمین زد و مقدار آن را می‌توان به عنوان احتمال اینکه طبقه بندی کننده تقلب‌ها را بالاتر از تراکنش‌های واقعی رتبه بندی می‌کند تفسیر کرد. یکی دیگر از معیارهای رتبه‌بندی که اغلب در تشخیص تقلب استفاده می‌شود، دقت متوسط است که با ناحیه زیر منحنی فراخوانی دقیق مطابقت دارد. در حالی که این معیارها به طور گسترده در مشکلات تشخیص استفاده می‌شوند، معیارهای مبتنی بر هزینه به طور خاص برای اهداف کشف تقلب طراحی شده‌اند. معیارهای مبتنی بر هزینه، زیان پولی کلاهبرداری را با استفاده از ماتریس هزینه که هزینه را با هر ورودی ماتریس سردرگمی مرتبط می‌کند، تعیین می‌کند. الکان نشان می‌دهد که یک ماتریس

هزینه ممکن است گمراه کننده باشد زیرا حداقل/حداکثر از دست دادن مشکل می تواند در طول زمان تغییر کند. برای جلوگیری از این مشکل، هزینه عادی یا صرفه جویی برای ارزیابی عملکرد با توجه به حداکثر ضرر استفاده می شود.

ما استدلال می کنیم که معیارهای عملکرد باید در دسترس بودن محققین را نیز در نظر بگیرند، زیرا آنها باید تمام هشدارهای ارائه شده توسط FDS را بررسی کنند. با توجه به زمان محدودی که محققین در اختیار دارند، فقط چند هشدار را می توان هر روز تأیید کرد، و بنابراین یک FDS موثر باید تعداد کمی هشدار قابل اعتماد را به محققان ارائه دهد. به همین دلیل است که ما اقدامات دقیق هشدار شرح داده شده در بخش 3 را معرفی کرده ایم.

C. چالش های عمده ای که باید در یک FDS دنیای واقعی پرداخته شوند

همانطور که در بخش اول پیش بینی می شود، چالش های عمده ای که در طراحی FDS باید مورد توجه قرار گیرد عبارتند از: (1) رسیدگی به عدم تعادل کلاس، زیرا تعداد تراکنش های قانونی بسیار بیشتر از تراکنش های تقلبی است. (2) مدیریت مفهوم رانش از آنجایی که ویژگی های آماری تقلب ها و معاملات واقعی با گذشت زمان تکامل می یابد. و (3) فعالیت با تعداد کمی از تراکنش های نظارت شده اخیر، که در قالب بازخورد محققین ارائه شده است.

(1) عدم تعادل طبقاتی: توزیع طبقاتی در تراکنش های کارت اعتباری بسیار نامتعادل است، زیرا کلاهبرداری ها معمولاً کمتر از 1٪ از کل تراکنش ها هستند. یادگیری در شرایط عدم تعادل کلاس اخیراً توجه زیادی را به خود جلب کرده است، زیرا روش های یادگیری سنتی طبقه بندی کننده هایی را ارائه می دهند که عملکرد ضعیفی در کلاس اقلیت دارند، که قطعاً کلاس مورد علاقه در مشکلات تشخیص است. چندین تکنیک برای مقابله با عدم تعادل طبقاتی پیشنهاد شده است و برای بررسی جامع، خواننده را به آن ارجاع می دهیم. دو رویکرد اصلی برای مقابله با عدم تعادل طبقاتی عبارتند از: (1) روش های نمونه گیری و (2) روش های مبتنی بر هزینه. روش های نمونه گیری برای متعادل کردن توزیع کلاس در مجموعه آموزشی قبل از اجرای یک الگوریتم یادگیری سنتی استفاده می شود، در حالی که روش های مبتنی بر هزینه، الگوریتم یادگیری را تغییر می دهند تا هزینه طبقه بندی اشتباه بزرگ تری را به کلاس اقلیت اختصاص دهند.

روش های نمونه گیری به دو دسته تقسیم می شوند که با حذف نمونه ها از کلاس اکثریت، نسبت های کلاس را در مجموعه آموزشی متعادل می کند، و روش های نمونه گیری بیش از حد که با تکرار نمونه های آموزشی کلاس اقلیت به همین هدف دست می یابند. روش های پیشرفته نمونه برداری بیش از حد، مانند

SMOTE، به جای تکرار نمونه، نمونه‌های آموزشی مصنوعی را از کلاس اقلیت با درون‌یابی تولید می‌کنند.

روش‌های مبتنی بر هزینه نیازی به متعادل کردن نسبت داده‌های آموزشی ندارند، زیرا آنها ضررهای متفاوتی را برای خطاهای طبقه‌بندی در نمونه‌های متعلق به کلاس اقلیت و اکثریت در نظر می‌گیرند. در تشخیص کلاهبرداری کارت اعتباری، هزینه کلاهبرداری از دست رفته اغلب متناسب با مبلغ تراکنش فرض می‌شود و این هزینه طبقه‌بندی اشتباه بزرگ‌تری را به کلاهبرداری‌ها اختصاص می‌دهد، بنابراین طبقه‌بندی کننده را به ترجیح دادن هشدارهای نادرست به جای پذیرش خطر از دست دادن یک کلاهبرداری هدایت می‌کند. در نتیجه، این الگوریتم‌ها ممکن است بسیاری از موارد مثبت کاذب را ایجاد کنند در حالی که محققان به هشدارهای دقیق نیاز دارند.

(2) رانش مفهومی: دو عامل اصلی ایجاد تغییرات/تحول در جریان تراکنش‌های کارت اعتباری هستند که در ادبیات معمولاً به عنوان رانش مفهومی شناخته می‌شوند. در ابتدا، تراکنش‌های واقعی به این دلیل تکامل می‌یابند که دارندگان کارت معمولاً رفتارهای خرج کردن خود را در طول زمان تغییر می‌دهند (به عنوان مثال، در طول تعطیلات، خریدشان بیشتر و متفاوت از بقیه سال است). دوم، کلاهبرداری‌ها در طول زمان تغییر می‌کنند، زیرا فعالیت‌های کلاهبرداری جدید انجام می‌شود. در آزمایش‌های خود (به بخش 6-D مراجعه کنید)، ماهیت در حال تحول تراکنش‌های کارت اعتباری را در دو مجموعه داده بزرگ از معاملات تجارت الکترونیک دنیای واقعی مشاهده می‌کنیم. یادگیری تحت انحراف مفهومی یکی از چالش‌های عمده‌ای است که روش‌های مبتنی بر داده باید با آن مواجه شوند، زیرا طبقه‌بندی‌کننده‌هایی که در این شرایط کار می‌کنند در عمل باید به‌طور مستقل مرتبط‌ترین اطلاعات نظارت‌شده به‌روز را شناسایی کنند و در عین حال اطلاعات منسوخ را نادیده بگیرند. رویکردهای سازگاری رانش مفهومی را می‌توان به دو خانواده تقسیم کرد: (1) سازگاری فعال و (2) سازگاری غیرفعال.

رویکردهای فعال از آزمون تشخیص تغییر یا سایر محرک‌های آماری برای نظارت بر داده‌های دریافتی با تجزیه و تحلیل خطای طبقه‌بندی و/یا توزیع داده‌ها استفاده می‌کنند. به محض اینکه تغییری در داده‌های دریافتی شناسایی شد، سازگاری فعال می‌شود و طبقه‌بندی‌کننده بر روی نمونه‌های نظارت‌شده اخیر که منسجم با وضعیت فعلی فرآیند در نظر گرفته می‌شوند، به‌روزرسانی/بازآموزی می‌شود. به این ترتیب، رویکردهای فعال بیشتر زمانی مناسب هستند که توزیع داده‌ها به‌طور ناگهانی تغییر می‌کند، و فرآیند تولید داده‌ها از طریق دنباله‌ای از حالت‌های ثابت جابجا می‌شود.

در رویکردهای غیرفعال، طبقه‌بندی‌کننده به‌طور پیوسته به‌روزرسانی می‌شود که نمونه‌های تحت نظارت جدید در دسترس قرار می‌گیرند، بدون اینکه هیچ مکانیزم تحریک آشکاری در آن دخالت داشته باشد.

روش‌های مجموعه و طبقه‌بندی‌کننده‌های آموزش‌دیده بر روی یک پنجره کشویی از نمونه‌های نظارت شده اخیر (مانند STAGGER و FLORA) احتمالاً گسترده‌ترین راه‌حل‌های غیرفعال هستند. رویکردهای غیرفعال در محیط‌های در حال حرکت تدریجی و زمانی که اطلاعات نظارت شده به صورت دسته‌ای ارائه می‌شوند، مناسب‌تر هستند.

هنگامی که جریان‌های داده با رانش مفهومی و توزیع‌های نامتعادل مشخص می‌شوند، تطبیق اغلب با ترکیب روش‌های مجموعه و تکنیک‌های نمونه‌گیری مجدد حاصل می‌شود. یک رویکرد جایگزین عبارت است از انتشار نمونه‌های آموزشی طبقه اقلیت در طول زمان، احتمالاً نمونه‌برداری کمتر از طبقه اکثریت. چن و او REA را پیشنهاد کردند که نمونه‌هایی را فقط از طبقه اقلیت که به مفهوم فعلی تعلق دارد، منتشر می‌کند.

(3) تعامل هشدار-بازخورد و سوگیری انتخاب نمونه: اکثر طبقه‌بندی‌کننده‌های مورد استفاده برای تشخیص تقلب کارت اعتباری در ادبیات، در آزمایش‌هایی آزمایش می‌شوند که قرار است برچسب‌های تراکنش از روز بعد از زمان مجاز شدن تراکنش در دسترس باشند. در یک FDS دنیای واقعی (بخش C-2)، تنها اطلاعات نظارت شده اخیر، بازخوردهای F_t است که توسط محققین ارائه می‌شود، در حالی که اکثریت قریب به اتفاق تراکنش‌های مجاز روزانه برچسبی در مدت کوتاهی دریافت نمی‌کنند ($|F_t| \ll |D_t|$). بازخوردها به دو دلیل عمده نشان‌دهنده تراکنش‌هایی نیستند که هر روز پردازش می‌شوند: (1) بازخوردها حاوی تراکنش‌هایی هستند که با احتمال زیاد کلاهبرداری مشخص می‌شوند و (2) نسبت تقلب‌ها در بازخوردها با نسبت تقلب‌هایی که روزانه رخ می‌دهند متفاوت است. بنابراین، بازخوردها نوعی مجموعه آموزشی مغرضانه را نشان می‌دهند: این مشکل چیزی را که در ادبیات به عنوان SSB شناخته می‌شود، تداعی می‌کند.

یک مجموعه آموزشی مغرضانه ممکن است عملکرد الگوریتم‌های یادگیری را مختل کند، زیرا داده‌های آموزشی با توزیع نمونه‌های آزمایشی مطابقت ندارند. در اینجا به سادگی اشاره می‌کنیم که سه نوع مختلف SSB وجود دارد! (SSBs): سوگیری کلاس قبلی، سوگیری ویژگی (همچنین تغییر متغیر نامیده می‌شود)، و سوگیری کامل. یک راه حل استاندارد برای SSB، وزن دهی اهمیت است، یعنی تکنیک‌های وزن دهی مجدد نیمه نظارتی که وزن‌های بزرگ‌تری را به نمونه‌های تمرینی که شباهت بیشتری به توزیع داده‌ها در مجموعه آزمون دارند، اختصاص می‌دهد. ایده اصلی وزن دهی اهمیت، کاهش تأثیر مغرضانه‌ترین نمونه‌ها در فرآیند یادگیری است. مجموعه‌هایی از طبقه‌بندی‌کننده‌ها نیز برای تصحیح SSB پیشنهاد شده‌اند.

تعامل بین FDS (افزایش هشدارها) و محققین (ارائه برچسب‌های واقعی) سناریوی یادگیری فعال را به یاد می‌آورد، که در آن می‌توان نمونه‌های بسیار آموزنده‌ای را انتخاب کرد و برچسب‌های آن‌ها را برای یک اوراکل جستجو کرد که در FDS محققین هستند. با این حال، این در یک FDS در دنیای واقعی امکان پذیر نیست، زیرا بازرسان باید روی مشکوک ترین تراکنش‌ها تمرکز کنند تا بیشترین تعداد تقلب‌ها را شناسایی کنند. درخواست‌ها برای بررسی تراکنش‌های (احتمالاً واقعی) برای دریافت نمونه‌های اطلاعاتی نادیده گرفته می‌شوند. با توجه به تعداد محدودی از تراکنش‌هایی که محققین می‌توانند بررسی کنند، پرداختن به این سؤالات لزوماً به این معنی است که برخی از تراکنش‌های پرخطر کنترل نمی‌شوند و در نتیجه عملکرد شناسایی از دست می‌رود.

5- استراتژی یادگیری پیشنهادی

مهم است که تاکید کنیم بازخوردها (F_t) و نمونه‌های تاخیری ($D_{t-\delta}$) مجموعه‌های بسیار متفاوتی از نمونه‌های نظارت شده هستند. اولین تفاوت کاملاً مشهود است: F_t اطلاعات به روز اخیر را ارائه می‌دهد در حالی که $D_{t-\delta}$ ممکن است برای آموزش طبقه‌بندی کننده‌ای که برای تجزیه و تحلیل تراکنش‌هایی که روز بعد مجاز می‌شوند منسوخ شده باشد. تفاوت دوم مربوط به درصد تقلب‌ها در F_t و $D_{t-\delta}$ است: در حالی که نسبت کلاس در $D_{t-\delta}$ به شدت به سمت کلاس واقعی منحرف می‌شود (نسبت‌های تقلب‌ها را در جدول 1 ببینید)، تعداد تقلب‌ها در F_t در واقع به این بستگی دارد. عملکرد تشخیص \mathcal{K}_{t-1} و مقادیر دقت بالا حتی ممکن است منجر به انحراف F_t به سمت تقلب شود. سومین و احتمالاً ظریف‌ترین تفاوت این است که زوج‌های تحت نظارت در F_t به طور مستقل ترسیم نمی‌شوند، بلکه تراکنش‌هایی از کارت‌هایی هستند که توسط \mathcal{K}_{t-1} به عنوان کارت‌هایی انتخاب شده‌اند که به احتمال زیاد تقلب شده‌اند. به این ترتیب، F_t تحت تأثیر SSB قرار می‌گیرد و هر طبقه‌بندی کننده‌ای که در F_t آموزش دیده باشد، اصولاً یاد می‌گیرد که چگونه تراکنش‌هایی را که به احتمال زیاد تقلبی هستند برچسب گذاری کند. بنابراین، این ممکن است در اصل در اکثریت قریب به اتفاق معاملات واقعی دقیق نباشد.

شهود ما این است که بازخوردها و نمونه‌های تاخیری نشان‌دهنده دو مشکل طبقه‌بندی متفاوت هستند، و بنابراین باید به طور جداگانه مورد بررسی قرار گیرند. بنابراین، استراتژی یادگیری ما شامل آموزش یک طبقه‌بندی کننده منحصرراً بر روی بازخوردها (یعنی F_t) و یک طبقه‌بندی کننده منحصرراً بر روی نمونه‌های نظارت شده با تأخیر (یعنی D_t) و با جمع‌آوری احتمالات پسین آنها هنگام تعریف $\mathcal{P}_{\mathcal{K}_t}(+|x_i)$ برای تعیین اینکه کدام تراکنش‌ها، برای هشدار دادن است.

در ادامه، استراتژی یادگیری پیشنهادی را به تفصیل شرح می‌دهیم، جایی که انطباق بر اساس یک رویکرد غیرفعال انجام می‌شود و طبقه‌بندی‌کننده هر روز بر روی دسته‌ای حاوی آخرین زوج‌های تحت نظارت موجود، بازخورد یا نمونه‌های تاخیری، به‌روزرسانی می‌شود. همانطور که در بخش 3، ما تأخیر تأیید ثابت δ روز را در نظر می‌گیریم. به ویژه، برای پردازش تراکنش‌های مجاز در روز $t + 1$ ، ما به Q روز بازخورد $\{F_t, \dots, F_{t-(Q-1)}\}$ و M روز از نمونه‌های نظارت شده با تأخیر $\{D_{t-\delta}, \dots, D_{t-(\delta+M-1)}\}$ ، و این دومی آشکارا شامل بازخوردهای دریافت شده در همان روزها می‌شود (یعنی $F_i \subset D_i, i \leq t - \delta$). استراتژی یادگیری ما، که در الگوریتم 1 به تفصیل آمده است، شامل آموزش جداگانه طبقه‌بندی‌کننده \mathcal{F}_t بر روی بازخوردها است.

$$\mathcal{F}_t = \text{TRAIN}(\{F_t, \dots, F_{t-(Q-1)}\}) \quad (7)$$

و یک طبقه‌بندی‌کننده در نمونه‌های نظارت شده با تأخیر

$$\mathcal{D}_t = \text{TRAIN}(\{D_{t-\delta}, \dots, D_{t-(\delta+M-1)}\}) \quad (8)$$

و برای شناسایی تقلب‌ها توسط طبقه‌بندی‌کننده تجمع \mathcal{A}_t ، که احتمال بعدی آن به صورت تعریف شده است.

$$\mathcal{P}_{\mathcal{A}_t}(+|x) = \alpha \mathcal{P}_{\mathcal{F}_t}(+|x) + (1 - \alpha) \mathcal{P}_{\mathcal{D}_t}(+|x) \quad (9)$$

که در آن $0 \leq \alpha \leq 1$ پارامتر وزنی است که سهم \mathcal{F}_t و \mathcal{D}_t را متعادل می‌کند. بنابراین، احتمال پسین طبقه‌بندی‌کننده \mathcal{K}_t ، که به تراکنش‌های مجاز در روز $t + 1$ هشدار می‌دهد، با (9) داده می‌شود.

پارامترهای Q و M که به ترتیب تعیین می‌کنند چند روز بازخورد و نمونه‌های نظارت شده با تأخیر برای آموزش طبقه‌بندی‌کننده‌های ما استفاده می‌شوند، باید با در نظر گرفتن تعداد کلی بازخوردها و درصد تقلب‌ها تعریف شوند. مجموعه آموزشی \mathcal{F}_t تقریباً حاوی Q است. $|F_t|$ نمونه‌ها (تعداد متفاوتی از بازخوردها ممکن است هر روز ارائه شود) و این تعداد باید به اندازه کافی بزرگ باشد تا طبقه‌بندی‌کننده‌ای را آموزش دهد که به یک مشکل طبقه‌بندی چالش برانگیز در ابعاد بالا رسیدگی کند. با این حال، Q را نمی‌توان به طور دلخواه بزرگ کرد، بدون اینکه بازخوردهای قدیمی را شامل شود. ملاحظات مشابهی در هنگام تنظیم M ، تعداد روزهای در نظر گرفته شده حاوی تراکنش‌های تاخیری، که باید شامل تعداد کافی تقلب باشد، وجود دارد. توجه داشته باشید که با این وجود امکان گنجاندن بازخوردهای \mathcal{F}_t قبل از δ روز ($Q \geq \delta$) در مجموعه آموزشی وجود دارد و به ویژه در آزمایش‌های خود از $Q = \delta + M$ استفاده کردیم.

منطق پشت استراتژی یادگیری پیشنهادی دو جنبه دارد. در ابتدا، با آموزش یک طبقه‌بندی‌کننده (7) منحصرأ بر روی بازخوردها، ما ارتباط بیشتر با این نمونه‌های نظارت‌شده را تضمین می‌کنیم، که در غیر این صورت تعداد نمونه‌های نظارت شده با تأخیر، بیشتر می‌شوند. دوم، ما فقط به تراکنش‌هایی هشدار می‌دهیم که هم \mathcal{F}_t و هم \mathcal{D}_t به احتمال زیاد تقلب در نظر گرفته می‌شوند: این از این واقعیت ناشی می‌شود که، در عمل، به دلیل تعداد زیادی تراکنش‌هایی که روزانه پردازش می‌شوند، هشدارها با مقادیر \mathcal{P}_{A_t} که بسیار نزدیک به یک هستند مطابقت دارد. بیایید به یاد بیاوریم که \mathcal{F}_t و در نتیجه \mathcal{A}_t نیز به دلیل تعامل هشدار-بازخورد تحت تأثیر SSB قرار می‌گیرد. تنها نمونه‌های آموزشی که تحت تأثیر SSB قرار نمی‌گیرند، نمونه‌های نظارت شده با تأخیر هستند که، با این حال، ممکن است به دلیل رانش مفهومی منسوخ شوند.

Algorithm 1 Proposed Learning Strategy

Require: M and Q , i.e., the number of days of delayed samples and feedbacks to use, respectively; \mathcal{F}_t and \mathcal{D}_t classifiers previously trained.

$T_{t+1} \leftarrow$ transactions at day $t + 1$.

for each transaction $x \in T_{t+1}$ **do**

 compute $\mathcal{P}_{\mathcal{F}_t}(+, x)$

 compute $\mathcal{P}_{\mathcal{D}_t}(+, x)$

 compute $\mathcal{P}_{A_t}(+, x)$ as in (9)

rank T_{t+1} according to $\mathcal{P}_{A_t}(+, \cdot)$,

generate alerts A_t .

if update the classifier **then**

$F_{t+1} \leftarrow$ feedbacks from cards alerted in A_t .

$\mathcal{F}_{t+1} \leftarrow \text{TRAIN}(\{F_{t+1}, \dots, F_{t-Q}\})$

$D_{t+1-\delta} \leftarrow$ transactions authorized at $t + 1 - \delta$

$\mathcal{D}_{t+1} \leftarrow \text{TRAIN}(\{D_{t+1-\delta}, \dots, D_{t-(\delta+M)}\})$

return \mathcal{F}_t , \mathcal{D}_t and \mathcal{A}_t defined as in (9).

A. اجرای استراتژی یادگیری پیشنهادی

در آزمایش‌های خود، استراتژی یادگیری پیشنهادی را در دو سناریو مختلف اجرا می‌کنیم که با دو رویکرد اصلی برای یادگیری \mathcal{D}_t مطابقت دارد. در اولی، یک طبقه‌بندی‌کننده پنجره کشویی است که آن را با \mathcal{W}_t^D نشان

می‌دهیم، در حالی که در دومی، \mathcal{D}_t مجموعه‌ای از طبقه‌بندی‌کننده‌ها است که ما با \mathcal{E}_t^D نشان دهیم. هر دو طبقه بندی کننده \mathcal{W}_t^D و \mathcal{E}_t^D بر روی نمونه های تاخیری آموزش داده شده اند $\{D_{t-\delta}, \dots, D_{t-(\delta+M-1)}\}$. با این حال، در حالی که \mathcal{W}_t^D از یک مدل منحصر به فرد برای این منظور استفاده می کند، \mathcal{E}_t^D مجموعه ای از M طبقه بندی کننده $\{\mathcal{M}_1, \mathcal{M}_2, \dots, \mathcal{M}_M\}$ که در آن هر طبقه بندی کننده \mathcal{M}_i جداگانه روی نمونه های تاخیری یک روز متفاوت آموزش داده می شود، یعنی $D_{t-\delta-i}$ ، $i=0, \dots, M-1$ ، خلفی $\mathcal{P}_{\mathcal{E}_t^D}(+|x)$ با میانگین گیری احتمالات خلفی طبقه بندی کننده های منفرد، یعنی $\mathcal{P}_{\mathcal{E}_t^D}(+|x) = \left(\frac{\sum_i^M \mathcal{P}_{\mathcal{M}_i}(+|x)}{M}\right)$ به دست می آید.

در مورد پنجره کشویی، استراتژی یادگیری پیشنهادی شامل تجزیه و تحلیل قسمت عقبی طبقه بندی کننده \mathcal{A}_t^W است که \mathcal{F}_t و \mathcal{W}_t^D را جمع می کند، یعنی $\mathcal{P}_{\mathcal{A}_t^W}(+|x) = \alpha \mathcal{P}_{\mathcal{F}_t}(+|x) + (1 - \alpha) \mathcal{P}_{\mathcal{W}_t^D}(+|x)$ مانند (9). معیار مقایسه با \mathcal{A}_t^W طبقه بندی کننده \mathcal{W}_t است که در مورد تمام تراکنش های نظارت شده با اشاره به بازه زمانی یکسان (در نتیجه ترکیب نمونه های تاخیری و بازخوردها) آموزش دیده است: $\{F_t, \dots, F_{t-(Q-1)}, D_{t-\delta}, \dots, D_{t-(\delta+M-1)}\}$.

به طور مشابه، در مورد مجموعه، استراتژی یادگیری پیشنهادی شامل تجزیه و تحلیل قسمت های پسین طبقه بندی کننده \mathcal{A}_t^E است که با جمع قسمت های خلفی \mathcal{F}_t و \mathcal{E}_t^D به دست می آید، یعنی $\mathcal{P}_{\mathcal{A}_t^E}(+|x) = \alpha \mathcal{P}_{\mathcal{F}_t}(+|x) + (1 - \alpha) \mathcal{P}_{\mathcal{E}_t^D}(+|x)$ مانند (9). معیار مقایسه با \mathcal{A}_t^E طبقه بندی کننده \mathcal{E}_t است که افراد آن $\{\mathcal{M}_1, \mathcal{M}_2, \dots, \mathcal{M}_M, \mathcal{F}_t\}$ و خلفی آن $\mathcal{P}_{\mathcal{E}_t}(+|x)$ با میانگین گیری احتمالات خلفی همه افراد آن تخمین زده می شود، یعنی $\mathcal{P}_{\mathcal{E}_t}(+|x) = \left(\frac{\sum_i^M \mathcal{P}_{\mathcal{M}_i}(+|x) + \mathcal{P}_{\mathcal{F}_t}(+|x)}{M+1}\right)$.

در هر دو جمع \mathcal{A}_t^E و \mathcal{A}_t^W ، $\alpha = 0.5$ را تنظیم کردیم تا سهم برابری در بازخورد و طبقه بندی کننده تاخیری داشته باشیم، همانطور که در بخش 6-F بهتر بحث خواهد شد. برای همه طبقه بندی کننده های پایه درگیر (به عنوان مثال، $\mathcal{F}_t, \mathcal{W}_t^D, \mathcal{W}_t, \mathcal{M}_i, i = 1, \dots, M$)، ما RF را که هر کدام 100 درخت دارد، اتخاذ می کنیم. هر درخت بر روی یک نمونه راه انداز متعادل آموزش داده می شود، که با کم نمونه سازی تصادفی طبقه اکثریت و حفظ تمام نمونه های کلاس اقلیت در مجموعه آموزشی مربوطه به دست می آید. به این ترتیب، هر درخت در مورد تراکنش های واقعی به طور تصادفی انتخاب شده و بر روی نمونه های تقلب مشابه آموزش داده می شود. این استراتژی کم نمونه سازی به فرد اجازه می دهد تا درختان را با توزیع متعادل یاد بگیرد و از بسیاری از زیر مجموعه های کلاس، اکثریت بهره برداری کند. در عین حال، زمان آموزش این دسته بندی کننده ها به طور معقولی کم است. یک اشکال کم نمونه گیری این است که ما به طور بالقوه نمونه های آموزشی مرتبط را از مجموعه داده ها حذف می کنیم، اگرچه این مشکل با این واقعیت کاهش می یابد که ما 100 درخت مختلف را برای هر طبقه بندی کننده پایه یاد می گیریم.

6-آزمایش

آزمایشات ما به شرح زیر سازماندهی شده است. در بخش 6-A، مجموعه داده ها را توصیف می کنیم و در بخش 6-B، تنظیمات آزمایشی را به تفصیل شرح می دهیم. بخش 6-C اولین آزمایش ما را ارائه می کند که از طبقه بندی کننده های شرح داده شده در بخش 5-A برای ارزیابی اثربخشی استراتژی یادگیری پیشنهادی استفاده می کند. در آزمایش دوم (بخش 6-D)، ما بیش از 54 میلیون تراکنش کارت اعتباری را که در طی 10 ماه به دست آمده اند، تجزیه و تحلیل می کنیم و نشان می دهیم که این جریان به طور جدی تحت تأثیر رانش مفهومی قرار گرفته است. سپس، برای بررسی توانایی انطباق استراتژی یادگیری پیشنهادی، ما به طور مصنوعی یک رانش مفهومی ناگهانی را در مکان های خاصی از جریان تراکنش معرفی می کنیم و عملکرد طبقه بندی را ارزیابی می کنیم. در آزمایش سوم (بخش 6-E)، سوگیری انتخاب نمونه معرفی شده توسط تعامل هشدار-بازخورد را بررسی می کنیم، و نشان می دهیم که وزن دهی اهمیت یک تکنیک مرسوم برای اصلاح SSB در مجموعه های آموزشی موثر نیست. بازخوردها در نهایت، در بخش 6-F، مهم ترین پارامترهای موثر بر استراتژی یادگیری پیشنهادی را مورد بحث قرار می دهیم.

Id	Start day	End day	# Days	# Instances	# Features	% Fraud Trx
2013	2013-09-05	2014-01-18	136	21'830'330	51	0.19%
2014-2015	2014-08-05	2015-05-31	296	54'764'384	51	0.24%


جدول 1: DATA SETS

A. مجموعه داده های ما

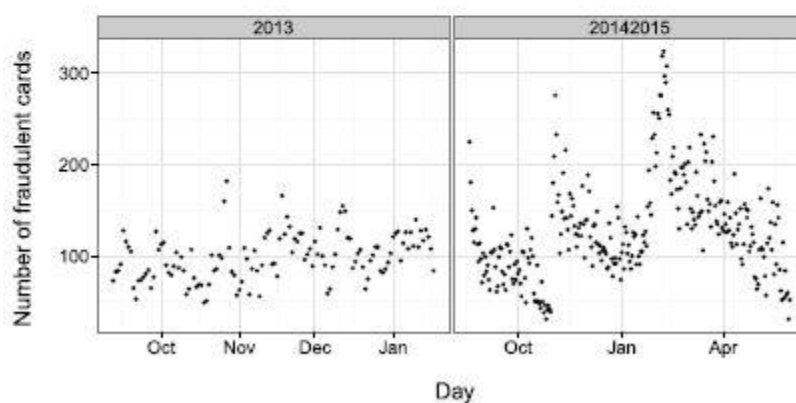
ما از دو مجموعه داده بزرگ از تراکنش های تجارت الکترونیک آنلاین از دارندگان کارت اعتباری اروپایی که توسط شریک صنعتی ما ارائه شده است استفاده می کنیم. حتی اگر این تراکنش ها از یک پایانه فیزیکی شروع نشده اند، اما تحت فرآیند مشابهی قرار می گیرند که در شکل 1 توضیح داده شده است. در جدول 1، ما تمام اطلاعات مربوط به این مجموعه داده ها را ارائه می کنیم، که به عنوان 2013 و 2014-2015، و به طور خاص مشخص می کنیم. ، ما بر عدم تعادل طبقاتی شدید تأکید می کنیم زیرا قلب ها حدود 0.2٪ از کل معاملات را تشکیل می دهند. همانطور که در شکل 3 نشان داده شده است، تعداد کلاهبرداری ها در هر روز به طور قابل توجهی در طول زمان متفاوت است و تراکنش های کلاهبرداری بیشتر از کارت های متقلبانه وجود دارد که نشان می دهد گاهی اوقات کلاهبرداری های متعددی در یک کارت انجام می شود.

برای ارزیابی قابل اعتماد عملکرد تشخیص تقلب بر حسب P_k ، مؤلفه CARD_ID را از همه بردارهای ویژگی حذف کردیم. این در هنگام آزمایش یک طبقه بندی کننده بر روی مجموعه داده ای از تراکنش های تاریخی بسیار

مهم است، زیرا طبقه‌بندی‌کننده‌ای که متغیر **CARD_ID** ورودی را دریافت می‌کند ممکن است این را به عنوان یک ویژگی متمایز برای شناسایی تقلب‌های متعدد از یک کارت در روزهای مختلف یاد بگیرد (در نتیجه عملکرد بسیار خوش‌بینانه ارائه می‌کند). با این حال، در یک **FDS** دنیای واقعی، پس از شناسایی اولین مورد، امکان تقلب‌های متعدد از یک کارت وجود ندارد، زیرا همانطور که در بخش دوم بحث شد، آن کارت بلافاصله مسدود می‌شود. یک گزینه متفاوت حذف تمام تراکنش‌های یک کارت پس از شناسایی اولین تقلب است. با این حال، این تعداد تقلب‌های موجود را کاهش می‌دهد و عدم تعادل طبقاتی در مجموعه داده‌های ما را بدتر می‌کند. بنابراین، ما **CARD_ID** را منحصراً برای محاسبه ویژگی‌های انبوه در نظر می‌گیریم و آن را در بردارهای ویژگی لحاظ نمی‌کنیم.



(a)



(b)



شکل 3: تعداد تراکنش‌ها و کارت‌های تقلبی در روز در مجموعه داده‌های شرح داده شده در جدول 1. مشخص می‌شود که تراکنش‌های کلاهبرداری بیشتر از کارت‌ها وجود دارد، به این معنی که برخی از کارت‌ها بیش از یک کلاهبرداری دریافت کرده‌اند. (a) تعداد معاملات متقلبانه. (b) تعداد کارت‌های تقلبی.

B. تنظیمات آزمایشی

در توافق با شریک صنعتی خود، ما فرض کردیم که بازرسان می توانند هر روز حداکثر 100 کارت هشدار داده شده توسط DDM را بررسی کنند. بنابراین، F_t هر روز در طول Q روز آموزش داده می شود که شامل هر تراکنش هشدار از 100 دارنده کارت مختلف است. به یاد بیاوریم که بازخوردها به طبقه بندی کننده واقعی که برچسب ها را درخواست می کند بستگی دارد. به این ترتیب، مجموعه آموزشی F_t ممکن است هنگام استفاده در A_t و زمانی که به طور مستقل استفاده می شود متفاوت باشد: در واقع، در مورد اول، هشدارها به خلفی (قسمت عقبی) D_t نیز بستگی دارند، در حالی که در دومی، هشدارها به طور منحصر به فرد توسط F_t تعیین می شوند.

ما عملکرد کلی تشخیص تقلب را در مجموعه داده های خود با میانگین معیارهای عملکرد روزانه (CP_k, P_k) و AUC) و همچنین با تجزیه و تحلیل مجموع رتبه های طبقه بندی کننده در هر روز ارزیابی می کنیم. به ویژه، در هر روز j ، طبقه بندی کننده های آزمایش شده S را از بهترین تا کم بازده رتبه بندی می کنیم و با $r_{\mathcal{H},j} \in \{1, \dots, S\}$ نشان می دهیم. رتبه طبقه بندی کننده K در روز j وقتی K بهترین طبقه بندی کننده است، رتبه آن حداکثر است، یعنی، $r_{\mathcal{H},j} = S$ ، در حالی که وقتی بدترین است، $r_{\mathcal{H},j} = 1$. آزمون فریدمن را انجام می دهیم و این فرضیه صفر را رد می کنیم که همه طبقه بندی کننده ها عملکرد یکسانی دارند. سپس، با جمع کردن تمام رتبه های روزانه، یک رتبه بندی جهانی را تعریف می کنیم (جدول 2 را ببینید): هر چه مجموع رتبه ها بزرگتر باشد، طبقه بندی کننده بهتر است، و از آزمون های t زوجی برای تعیین اینکه آیا تفاوت ها در رتبه بندی جهانی معنی دار هستند یا خیر استفاده می کنیم. در عمل، برای هر جفت طبقه بندی کننده K و H ، از آزمون t برای مقایسه رتبه های آنها در تمام روزها استفاده می شود (یعنی $\{1, \dots, J\}$ ، J تعداد روزها).

هر آزمایش 10 بار تکرار می شود تا تغییرپذیری عملکرد کاهش یابد، و هنگام مقایسه طبقه بندی کننده ها در چند روز، شاخص t را از نماد طبقه بندی حذف می کنیم. در بیشتر آزمایش هایمان، یک هفته تأخیر تأیید $\delta = 7$ و $M = 8$ را در نظر می گیریم، به طوری که تعداد کلی بازخوردهای مورد استفاده $Q = M + \delta = 15$ است. در بخش 6-F، آزمایش ها را تکرار می کنیم. با در نظر گرفتن تاخیر تأیید طولانی تر $\delta = 15$ و $M = 15$. $Q = 30$.



شکل 4: اطلاعات نظارت شده که توسط طبقه‌بندی‌کننده‌ها در نظر گرفته شده در آزمایش‌های ما استفاده می‌شود. در این مثال گویا، ما $\delta = 7$ ، $M = 2$ و $Q = 7 + 2 = 9$ را تنظیم کردیم. (a) ادغام تمام تراکنش‌های برجسب دار. (b) تفکیک بازخوردها و نمونه‌های تاخیری.

C. جداسازی بازخوردها از نمونه‌های نظارت شده با تاخیر

برای ارزیابی اثربخشی استراتژی یادگیری پیشنهادی، عملکرد طبقه‌بندی‌کننده‌های پیشنهادی \mathcal{A}^W (مثلاً \mathcal{A}^E) را با معیارهای مربوطه معرفی شده در بخش A-5 و طبقه‌بندی‌کننده‌های مورد استفاده برای تعریف پسین آنها، یعنی \mathcal{F} و \mathcal{W}^D (مثلاً \mathcal{E}^D) مقایسه می‌کنیم. شکل 4 مجموعه آموزشی مربوط به استفاده از \mathcal{A}_t^W و طبقه‌بندی‌کننده‌های مرتبط را نشان می‌دهد، در حالی که جدول 3 مهم‌ترین پارامترها و نمونه‌های آموزشی مورد استفاده توسط طبقه‌بندی‌کننده‌های در نظر گرفته شده را خلاصه می‌کند.

در این آزمایش، طبقه‌بندی‌کننده ایده‌آل \mathcal{R}_t را نیز گنجانده‌ایم که در تمام تراکنش‌های مجاز بین روزهای t و $t-\delta$ آموزش داده شده است. این طبقه‌بندی‌کننده یک همتای ایده‌آل برای طبقه‌بندی‌کننده‌های پنجره کشویی

در نظر گرفته می‌شود، که به طور غیرواقعی فرض می‌کنند که محققین می‌توانند هر روز برچسب صحیح را به هر تراکنش مجاز اختصاص دهند. به طور خاص، مجموعه آموزشی \mathcal{R}_t تحت تأثیر تعامل هشدار-بازخورد قرار نمی‌گیرد.

Classifier	Dataset	Average P_k			Average CP_k			Average AUC		
		mean (std)	sum of ranks	comparison	mean (std)	sum of ranks	comparison	mean (std)	sum of ranks	comparison
\mathcal{A}^W	2014-2015	0.77 (0.21)	1796.50	a	0.37 (0.18)	1824.00	a	0.94 (0.02)	1396.00	b
\mathcal{F}	2014-2015	0.73 (0.23)	1632.00	b	0.32 (0.17)	1505.00	b	0.87 (0.05)	409.00	e
\mathcal{R}	2014-2015	0.63 (0.24)	1156.00	c	0.30 (0.18)	1354.50	c	0.96 (0.02)	1822.00	a
\mathcal{W}	2014-2015	0.61 (0.25)	1055.50	d	0.25 (0.14)	955.00	d	0.91 (0.04)	865.00	d
\mathcal{W}^D	2014-2015	0.57 (0.26)	889.00	e	0.25 (0.14)	885.00	e	0.94 (0.03)	1315.00	c
\mathcal{A}^W	2013	0.75 (0.20)	732.00	a	0.35 (0.12)	754.50	a	0.94 (0.03)	631.00	b
\mathcal{F}	2013	0.73 (0.21)	693.00	b	0.32 (0.13)	670.50	b	0.89 (0.05)	229.00	e
\mathcal{R}	2013	0.58 (0.22)	493.50	c	0.25 (0.11)	514.00	c	0.96 (0.01)	736.00	a
\mathcal{W}	2013	0.54 (0.25)	434.00	d	0.22 (0.11)	387.00	d	0.91 (0.05)	355.00	d
\mathcal{W}^D	2013	0.50 (0.23)	345.00	e	0.21 (0.09)	330.00	e	0.93 (0.03)	539.00	c
\mathcal{A}^E	2014-2015	0.77 (0.21)	981.50	a	0.39 (0.17)	940.00	a	0.94 (0.03)	873.00	b
\mathcal{F}	2014-2015	0.73 (0.23)	827.50	b	0.36 (0.17)	800.50	b	0.87 (0.06)	294.00	d
\mathcal{E}	2014-2015	0.66 (0.25)	637.50	c	0.26 (0.14)	533.50	c	0.94 (0.03)	943.00	a
\mathcal{E}^D	2014-2015	0.54 (0.26)	323.50	d	0.23 (0.12)	276.00	d	0.93 (0.03)	660.00	c
\mathcal{A}^E	2013	0.76 (0.20)	410.50	a	0.37 (0.14)	335.00	a	0.94 (0.02)	380.00	a
\mathcal{F}	2013	0.73 (0.21)	354.00	b	0.35 (0.15)	285.00	b	0.89 (0.04)	129.00	c
\mathcal{E}	2013	0.62 (0.23)	246.50	c	0.24 (0.11)	193.00	c	0.93 (0.03)	374.00	a
\mathcal{E}^D	2013	0.48 (0.24)	119.00	d	0.20 (0.11)	97.00	d	0.93 (0.03)	247.00	b

جدول 2: عملکرد تشخیص تقلب هنگام استفاده از 15 روز تراکنش ($\delta = 7$, $M = 8$, و $Q = 15$)

جدول 2 میانگین P_k ، CP_k و AUC را در تمام دسته‌ها برای دو مجموعه داده به طور جداگانه نشان می‌دهد. مقایسه ستون‌ها نتایج آزمون t زوجی را در رتبه‌های شرح داده شده در بالا گزارش می‌دهد. طبقه بندی کننده‌هایی که حرف یکسانی دارند نمی‌توانند به طور قابل توجهی متفاوت در نظر گرفته شوند. در هر دو مجموعه داده، \mathcal{A}^W از نظر P_k و CP_k از \mathcal{W} بهتر عمل می‌کند، و این نشان می‌دهد که جداسازی بازخوردها و نمونه‌های تاخیری در واقع یک استراتژی یادگیری خوب است. همین نتیجه برای گروه‌های در نظر گرفته شده، یعنی \mathcal{A}^E و \mathcal{E} صدق می‌کند. از آنجایی که هر دو \mathcal{A}^E و \mathcal{E} میانگین قسمت‌های خلفی افراد خود را دارند، تفاوت آنها فقط در وزن‌های تجمع است: در \mathcal{A}^E ، 50٪ از وزن کل به $\mathcal{P}_{\mathcal{F}}(+|x)$ اختصاص می‌یابد. و 50٪ باقیمانده به طور مساوی بین افراد دیگر توزیع می‌شود. در مقابل، در \mathcal{E} همه افراد به طور مساوی مشارکت دارند. همین رابطه بین \mathcal{A}^W و \mathcal{W} که به صورت پنجره کشویی به روز می‌شوند برقرار نیست. با این حال، در این مورد نیز می‌توان نتیجه گرفت که بازخوردها بسیار آموزنده هستند و برای افزایش دقت هشدار باید به دقت در نظر گرفته شوند. این نیز با این واقعیت تأیید می‌شود که \mathcal{F} از \mathcal{W}^D و \mathcal{W} بهتر عمل می‌کند. به عنوان یک نظر کلی، ما متذکر می‌شویم که CP_k معمولاً کمتر از P_k است، زیرا اغلب تقلب‌های متعدد روی یک کارت انجام می‌شود.

جدول 2 همچنین نتایج را بر حسب AUC گزارش می‌کند، یک معیار رتبه‌بندی جهانی که پسین طبقه‌بندی کننده را در تمام نمونه‌ها و نه تنها در k بالا (متفاوت از CP_k و P_k) ارزیابی می‌کند. از نظر AUC،

طبقه‌بندی‌کننده ایده‌آل \mathcal{R} به‌طور قابل‌توجهی بهتر از \mathcal{A}^W است و \mathcal{F} به مراتب بدتر است، که نشان می‌دهد \mathcal{F} هنگام رتبه‌بندی همه تراکنش‌ها مؤثر نیست.

ما این نتایج را به صورت زیر تفسیر می‌کنیم: زمانی که هدف به دست آوردن یک رتبه بندی دقیق از مشکوک ترین کارت‌ها است (به عنوان مثال، حداکثر کردن CP_k)، باید وزن‌های بزرگ‌تری را به تراکنش‌هایی که به اندازه تراکنش‌هایی که می‌خواهیم پیش‌بینی کنیم مخاطره‌آمیز هستند، اختصاص دهیم، بنابراین از \mathcal{A}^W استفاده می‌کنیم. برعکس، یک طبقه‌بندی‌کننده آموزش‌دیده بر روی تمام تراکنش‌های روزانه (که عمدتاً واقعی هستند) در رتبه‌بندی همه تراکنش‌ها بهتر است، زیرا از ناحیه زیر منحنی \mathcal{R} (AUC) ROC بیرون می‌آید. در جدول 2، همچنین می‌توانیم ببینیم که \mathcal{R} از نظر P_k ، CP_k و AUC از \mathcal{W}^D بهتر عمل می‌کند. این نتیجه نشان می‌دهد که جریان تراکنش‌های کارت اعتباری غیر ثابت است. در واقع، هر دو مجموعه آموزشی \mathcal{R} و \mathcal{W}^D شامل تمام معاملات مجاز در $\delta = 7$ و $M = 8$ روز متوالی هستند. تفاوت عمده آنها در این است که \mathcal{R} در آخرین تراکنش‌ها آموزش دیده است، در حالی که تراکنش‌ها در \mathcal{W}^D با تاخیر δ روز انجام می‌شوند. این واقعیت که \mathcal{R} بهتر از \mathcal{W}^D عمل می‌کند نشان می‌دهد که جدیدترین تراکنش‌ها برای کشف تقلب‌ها در روزهای آینده اطلاعات بیشتری دارند و بنابراین توزیع تراکنش غیر ثابت است.

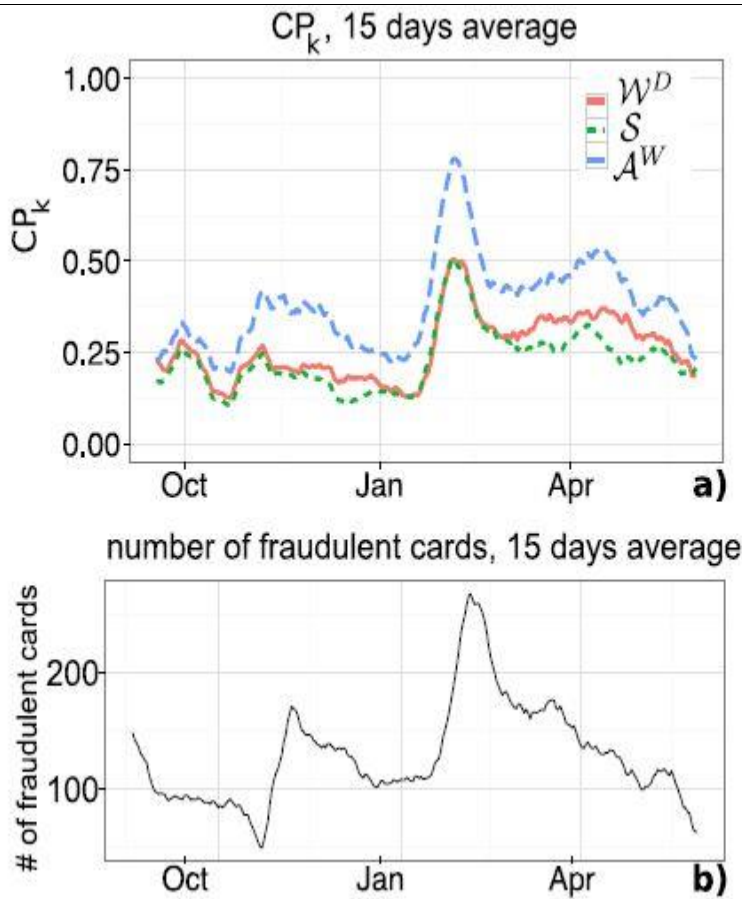
انحراف استاندارد P_k و CP_k که در جدول 2 گزارش شده است، به ویژه در مقایسه با AUC بسیار زیاد است. همانطور که در بخش 3 بحث کردیم، و همانطور که در شکل 5 نشان داده شده است، مقادیر CP_k (و همچنین P_k) به شدت تحت تاثیر تعداد تقلب‌هایی است که هر روز رخ می‌دهد. از آنجایی که این عدد در طول زمان به شدت در نوسان است (شکل 3 را ببینید)، انتظار چنین پراکندگی بزرگی منطقی است. ما خاطرنشان می‌کنیم که مقایسه بین طبقه‌بندی‌کننده‌ها در جدول 2 نشان می‌دهد که تفاوت‌ها از نظر عملکرد، با وجود چنین انحراف استاندارد زیاد، همیشه قابل توجه است. توجه داشته باشید که مقادیر NCP_k (به جدول 4 مراجعه کنید) کمتر تحت تأثیر چنین نوساناتی قرار می‌گیرند.

Symbol	supervised samples	adaptation	# days training
\mathcal{F}	feedbacks	sliding	Q
\mathcal{W}^D	delayed	sliding	M
\mathcal{W}	feedbacks + delayed	sliding	$\delta + M$
\mathcal{A}^W	feedbacks + delayed	sliding	$Q + M$
\mathcal{R}	all the recent	sliding	δ
\mathcal{E}^D	delayed	ensemble	M
\mathcal{E}	feedbacks + delayed	ensemble	$\delta + M$
\mathcal{A}^E	feedbacks + delayed	ensemble	$Q + M$

جدول 3: طبقه‌بندی‌کننده‌ها در آزمایش‌های ما در نظر گرفته شده‌اند

D. رانش مفهومی

در این بخش، ابتدا مجموعه داده‌های 2014-2015 را که شامل بیش از 54 میلیون تراکنش مجاز طی 10 ماه است، تجزیه و تحلیل می‌کنیم و نشان می‌دهیم که این جریان تحت تأثیر رانش مفهومی است. برای این منظور از طبقه‌بندی‌کننده استاتیک S_t استفاده می‌کنیم که در ابتدا در روز M آموزش داده می‌شود و هرگز به‌روزرسانی نمی‌شود (به‌طوری که در ابتدا با \mathcal{W}_t^D مصادف می‌شود) و آن را با \mathcal{W}_t^D (که در عوض مرتب به‌روزرسانی می‌شود) و \mathcal{A}_t^W (که همچنین از نمونه‌های نظارت شده به روز شده استفاده می‌کند) مقایسه می‌کنیم. در یک مسئله طبقه‌بندی ثابت، دو طبقه‌بندی‌کننده S و \mathcal{W}^D عملکرد مشابهی دارند. این واقعیت که S_t در طول زمان از \mathcal{W}_t^D بهتر عمل می‌کند [به شکل 5(a) مراجعه کنید] تأیید می‌کند که این مجموعه داده تحت تأثیر رانش مفهومی قرار گرفته است. اگرچه ممکن است تعجب آور به نظر نرسد که جریان تراکنش‌های کارت اعتباری غیر ثابت است، تا جایی که می‌دانیم، تحلیل ما اولین تحلیل در مورد تأثیر رانش مفهومی بر چنین مجموعه داده تراکنش بزرگی است.



classifier	mean	sd	sum of ranks	comparison	k
\mathcal{A}^W	0.48	0.09	506.00	a	300
\mathcal{F}	0.46	0.10	448.00	b	300
\mathcal{W}	0.38	0.11	283.00	c	300
\mathcal{W}^D	0.35	0.10	172.50	d	300
\mathcal{A}^W	0.41	0.10	519.50	a	150
\mathcal{F}	0.38	0.10	441.50	b	150
\mathcal{W}	0.29	0.10	272.50	c	150
\mathcal{W}^D	0.27	0.09	179.50	d	150
\mathcal{A}^W	0.40	0.13	518.50	a	100
\mathcal{F}	0.37	0.13	443.00	b	100
\mathcal{R}	0.29	0.10	342.50	c	100
\mathcal{W}^D	0.26	0.11	249.00	d	100

جدول 4. میانگین NCP_k هنگامی که $k \geq 100$ در مجموعه داده 2013 ($\delta = 15$)

شکل 5: (الف) مقادیر CP_k برای S ، \mathcal{W}^D و \mathcal{A}^W در مجموعه داده 2014-2015. (ب) تعداد کارتهای تقلبی در همان دوره. به منظور تجسم، این مقادیر به طور متوسط در یک پنجره کشویی 15 روزه محاسبه شده اند. اوج CP_k در (a) مطابق با اوج تعداد کارت های تقلبی در (b) است. این نتیجه تأیید می کند که طبقه بندی کننده ها در آن روزهایی که با تعداد زیادی کارت های تقلبی مشخص می شد، دقیق تر می شوند.

شکل 5(a) همچنین نشان می دهد که \mathcal{A}^W پیشنهادی همیشه از نظر CP_k به عملکرد برتر دست می یابد، که انطباق بهتری با رانش مفهومی را نشان می دهد. شایان ذکر است که عملکرد همه طبقه بندی کننده ها در شکل 5 (الف) کاملاً نوسان دارد و اوج خود را در فوریه 2015 گزارش می کند. این در واقع ماهی است که بیشترین تعداد کارت های تقلبی را در مجموعه داده ما دارد [که در گزارش شده است. شکل 5 (ب)]. در مقابل، در اکتبر 2014 (دوره ای که کمترین تعداد کارت های تقلبی را در مجموعه داده های ما نشان می دهد)، همه طبقه بندی کننده ها به مقادیر پایین CP_k دست می یابند. بنابراین، شکل 5 تأیید می کند که دقت هشدار به شدت به تعداد کارت های تقلبی در یک روز بستگی دارد.

برای بررسی بیشتر عملکرد انطباق \mathcal{A}^W در محیط های غیر ثابت، توانایی های انطباق آن را با توجه به یک رانش مفهومی معرفی شده مصنوعی ارزیابی می کنیم. به طور خاص، ما به طور مصنوعی تغییراتی را در مکان های شناخته شده معرفی می کنیم و یک جابجایی ناگهانی را در بالای (تدریجی) آنکه بر جریان تراکنش تأثیر می گذارد، اضافه می کنیم، که قبلاً در مورد آن بحث کردیم. ما 10 جریان کوتاه را با کنار هم قرار دادن معاملات مجاز در دو ماه غیر متوالی آماده کردیم. هر یک از این جریان ها شامل یک رانش مفهومی ناگهانی در وسط است، که وقتی فاصله زمانی بین ماه های کنار هم افزایش می یابد، باید به وضوح قابل درک باشد. برای ارزیابی توانایی انطباق استراتژی یادگیری پیشنهادی، عملکرد \mathcal{A}^W و \mathcal{W}^D را از نظر CP_k مقایسه می کنیم. به طور خاص، ما افت عملکرد نسبی ناشی از رانش مفهوم را به عنوان تفاوت بین CP_k در ماه اول و دوم، تقسیم بر مقدار CP_k در ماه اول اندازه گیری می کنیم. آزمایش های ما نشان می دهد که در این 10 مجموعه داده، 7.7% از CP_k از \mathcal{A}^W کاهش می یابد، در حالی که 12.5% از CP_k از \mathcal{W}^D کاهش می یابد که عملکرد انطباق برتر استراتژی یادگیری پیشنهادی را تأیید می کند.

E. سوگیری انتخاب نمونه به دلیل تعامل هشدار-بازخورد

در اینجا ما بررسی می کنیم که آیا وزن دهی اهمیت، یک راه حل اصلی برای اصلاح SSB، می تواند با موفقیت SSB معرفی شده توسط تعامل هشدار-بازخورد را جبران کند یا خیر؟ برای این منظور، طبقه بندی بازخورد \mathcal{F}_t

را در نظر می‌گیریم، زیرا این طبقه‌بندی‌کننده عمدتاً تحت تأثیر **SSB** به دلیل تعامل هشدار-بازخورد قرار می‌گیرد، و از پیاده‌سازی حساس به وزن **RF**ها بر اساس درخت‌های استنتاج شرطی استفاده می‌کنیم.

وزن دهی مهم شامل وزن دهی مجدد هر نمونه تمرین بر حسب فوت با استفاده از وزن زیر است:

$$w = \frac{P(s = 1)}{P(s = 1|x, y)} \quad (10)$$

که در آن s یک متغیر انتخابی است که به هر نمونه در T_t مقدار 1 را در صورتی که تراکنش بر حسب F_t باشد و 0 را در غیر این صورت مرتبط می‌کند. بنابراین، $P(s = 1|x, y)$ مربوط به احتمال قرار گرفتن نمونه (x, y) در مجموعه آموزشی F_t است. تعریف اوزان در (10) از قضیه بیز و این واقعیت ناشی می‌شود که می‌توان توزیع پیوستگی بی طرف $P(x, y)$ را با توجه به توزیع مشترک بایاس $P(x)$ بیان کرد. $P(x, y|s = 1)$ به عنوان:

$$P(x, y) = \frac{P(s = 1)}{P(s = 1|x, y)} P(x, y|s = 1) = w P(x, y|s = 1).$$

جدول 5 عملکرد به دست آمده در هنگام تصحیح **SSB** با استفاده از وزن های ارائه شده توسط (10) را گزارش می‌کند و مشخص می‌شود که این وزن ها از عملکرد به دست آمده توسط \mathcal{F} در جدول 2 کمتر است. وزن دهی اهمیت در واقع عملکرد \mathcal{F} را بهبود نمی‌بخشد، که ما آن را به عنوان یک شکست در هنگام جبران **SSB** معرفی شده توسط تعامل هشدار-بازخورد تفسیر می‌کنیم.

ما معتقدیم که وزن دهی اهمیت به دلیل تعامل هشدار-بازخورد، بی‌اثر می‌شود، زیرا $P(s = 1|x, y)$ و $P(+|x)$ در (10) همبستگی بالایی دارند. این بدان معناست که هر چه تراکنش بیشتر به عنوان ریسک در نظر گرفته شود، احتمال $P(s = 1|x, y)$ بیشتر است و وزن آن در (10) کمتر است. بنابراین، وزن دهی اهمیت، تأثیر آن نمونه‌ها را در بازخوردهایی که احتمال تقلب دارند، کاهش می‌دهد و این بر دقت هشدار تأثیر منفی می‌گذارد.

به عنوان یک بررسی عقلانی، ما این آزمایش را در چارچوبی تکرار کردیم که در آن نمونه‌های نظارت شده اخیر با تعامل هشدار-بازخورد ارائه نمی‌شوند، بلکه به‌طور تصادفی (در همان تعداد و نسبت‌های کلاس آزمایش فوق) از میان تراکنش‌هایی که مبلغی بزرگ‌تر از **AC500** دارند، انتخاب می‌شوند. این شکل از **SSB** به عنوان تغییر متغیر نامیده می‌شود زیرا ما $P(s|y, x) = P(s|x)$ داریم، یعنی با توجه به ورودی x ، متغیر انتخابی s مستقل از کلاس y است. در این مورد، وزن دهی اهمیت توانست این سوگیری را به درستی جبران کند و طبقه‌بندی‌کننده منحرف از طبقه‌بندی‌کننده مشابهی که بدون اصلاح **SSB** آموزش داده شده است، بهتر عمل می‌کند.

classifier	mean	sd	sum of ranks	comparison	dataset
\mathcal{A}^W	0.38	0.17	1671.00	a	2014-2015
\mathcal{F}	0.36	0.17	1482.50	b	2014-2015
\mathcal{R}	0.31	0.17	1234.50	c	2014-2015
\mathcal{W}	0.25	0.13	850.50	d	2014-2015
\mathcal{W}^D	0.24	0.12	705.50	e	2014-2015
\mathcal{S}	0.23	0.12	605.50	f	2014-2015
\mathcal{A}^W	0.38	0.14	609.00	a	2013
\mathcal{F}	0.35	0.14	541.00	b	2013
\mathcal{R}	0.27	0.11	411.50	c	2013
\mathcal{W}	0.25	0.13	325.50	d	2013
\mathcal{W}^D	0.24	0.12	281.00	e	2013
\mathcal{S}	0.20	0.12	198.00	f	2013

metric	mean	sd	dataset
P_k	0.68	0.26	2014-2015
P_k	0.59	0.26	2013
CP_k	0.26	0.16	2014-2015
CP_k	0.25	0.13	2013
AUC	0.85	0.06	2014-2015
AUC	0.85	0.06	2013

جدول 5: میانگین P_k ، CP_k و AUC برای \mathcal{F}_t وقتی $Q = 15$	جدول 6: میانگین CP_k هنگام استفاده از 30 روز ($\delta = 15$ ، $M = 15$ ، و $Q = 30$)
-------------------------------------------------------------------------	------------------------------------------------------------------------------------------

\mathcal{F} . تاثیر پارامترها

در اینجا نشان می‌دهیم که چگونه عملکرد \mathcal{F}_t و \mathcal{A}_t^W تحت تاثیر: (1) تعداد روزهای بازخورد در نظر گرفته شده برای آموزش طبقه‌بندی‌کننده‌های ما (یعنی Q) قرار می‌گیرد. (2) تعداد کارت‌هایی که هر روز توسط بازرسان کنترل می‌شوند. (3) پارامتر α که طبقه‌بندی‌کننده تجمع را در (9) تنظیم می‌کند. برای این منظور، ما $\delta = 15$ روز تأخیر تأیید را در نظر می‌گیریم، به طوری که \mathcal{F}_t در 30 روز بازخورد آموزش داده می‌شود ($Q = 30$ ، $M = 15$ ، و $\delta = 15$) و نمونه‌های نظارت شده با تأخیر پس از 15 روز می‌آیند. جدول 6 نشان می‌دهد که \mathcal{F} از نظر CP_k زمانی که با استفاده از $Q = 30$ روز بازخورد آموزش داده شود نسبت به $Q = 15$ بهتر است (جدول 2 را ببینید). همین امر برای \mathcal{A}^W ، به عنوان یک نتیجه از عملکرد برتر به دست آمده توسط \mathcal{F} ، صدق می‌کند. بنابراین، مقدار بیشتر بازخوردهای استفاده شده در طول آموزش به خوبی در این مورد افزایش تأخیر تأیید را جبران می‌کند.

ما این آزمایش را با در نظر گرفتن تعداد بیشتری بازخورد در روز تکرار می‌کنیم تا نشان دهیم این پارامتر چگونه بر عملکرد \mathcal{F} و \mathcal{A}^W تأثیر می‌گذارد. در جدول 4، فرض می‌کنیم که محققان می‌توانند بیش از 100 کارت را بررسی کنند و عملکرد تشخیص تقلب را بر حسب NCP_k گزارش کنند تا دقت هشدار را زمانی که بتوان کارت‌های بیشتری را کنترل کرد، به درستی ارزیابی کرد. این نتیجه تأیید می‌کند که داشتن بازخوردهای بیشتر، عملکرد برتر در تشخیص تقلب را تضمین می‌کند. این تجزیه و تحلیل می‌تواند به عنوان یک دستورالعمل برای شرکت‌هایی در نظر گرفته شود که باید تصمیم بگیرند که آیا هزینه‌های استخدام محققان بیشتر با بهبود مورد انتظار در عملکرد کشف تقلب جبران می‌شود یا خیر.

یکی دیگر از پارامترهای مهم در استراتژی یادگیری ما α است که سهم بازخورد و طبقه بندی کننده های تاخیری را در (9) متعادل می کند. این به طور تجربی پس از بررسی استراتژی های متعدد برای تطبیق این پارامتر به صورت روزانه روی 0.5 تنظیم شد. ایده ما این بود که دقت (یا سایر معیارهای عملکرد) به دست آمده در طول روز $t-1$ توسط \mathcal{F}_{t-1} و \mathcal{D}_{t-1} را در نظر بگیریم و سپس وزن هایی را به \mathcal{F}_t و \mathcal{D}_t نسبت دهیم (بهترین طبقه بندی کننده در طول روز $t-1$ بود. ، وزن در طول روز t بزرگتر است). متأسفانه، به نظر می رسد هیچ یک از راه حل های پیاده سازی شده از میانگین دو مورد پسین، یعنی $\alpha_t = 0.5 \forall t$ بهتر عمل نمی کند.

بنابراین، ما یک شبیه سازی گسترده را روی راه حل پنجره کشویی اجرا کردیم، جایی که هر روز $\alpha_t \in \{0.1, 0.2, \dots, 0.9\}$ را، آزمایش کردیم و سپس α_t^* را به عنوان یکی از آنها انتخاب می کنیم که تجمع را در بهترین حالت بر حسب P_k انجام می دهد. چنین انتخاب بهینه ای از وزن ها البته در یک FDS در دنیای واقعی امکان پذیر نیست، زیرا نیاز به درخواست بازخورد برای هر $\alpha_t \in \{0.1, 0.2, \dots, 0.9\}$ است. با این حال، تنظیم α_t^* روزانه حداقل بهبود را با توجه به تنظیم $\alpha_t = 0.5 \forall t$ به همراه داشت. این را می توان با این واقعیت توضیح داد که α_t^* توزیع اوج در حدود 0.5 داشت که میانگین $\alpha_t^* \approx 0.52$ داشت. مقدار P_k با نزدیک شدن به $\alpha = 0.1$ و $\alpha = 0.9$ به طور پیوسته کاهش می یابد، که نشان می دهد مقادیر شدید α به ندرت بهترین گزینه هستند. در این موارد شدید، \mathcal{A}_t به \mathcal{D}_t یا \mathcal{F}_t نزدیک می شود (که نشان داده شده است بهترین گزینه نیستند) و طبقه بندی کننده که کمترین وزن را دریافت می کند، شانس کمی برای درخواست بازخورد به منظور بهبود عملکرد و افزایش وزن خود دارد.

نتیجه

اکثر کارهایی که به مشکل کشف تقلب در تراکنش های کارت اعتباری می پردازند، به طور غیر واقعی فرض می کنند که کلاس هر تراکنش بلافاصله برای آموزش طبقه بندی کننده ارائه می شود. در اینجا ما شرایط کاری دنیای واقعی FDS را به تفصیل تجزیه و تحلیل می کنیم و یک توصیف رسمی از مشکل طبقه بندی مفصلی ارائه می کنیم. به طور خاص، ما تعامل هشدار-بازخورد را شرح داده ایم، که مکانیزمی است که نمونه های نظارت شده اخیر را برای آموزش به روزرسانی طبقه بندی کننده ارائه می کند. ما همچنین ادعا می کنیم که برخلاف معیارهای عملکرد سنتی که در ادبیات استفاده می شود، در یک FDS دنیای واقعی، دقت هشدارهای گزارش شده احتمالاً معنادارترین است، زیرا محققان می توانند تنها چند هشدار را بررسی کنند.

آزمایش های ما بر روی دو مجموعه داده گسترده از تراکنش های دنیای واقعی نشان می دهد که برای دریافت هشدارهای دقیق، دادن اهمیت بیشتری به بازخوردها در طول مشکل یادگیری الزامی است. جای تعجب نیست که بازخوردها نقش اصلی را در استراتژی یادگیری پیشنهادی ایفا می کنند، که شامل آموزش جداگانه طبقه بندی

کننده در مورد بازخوردها و طبقه‌بندی کننده بر روی نمونه‌های نظارت شده با تأخیر، و سپس جمع‌آوری پسین آنها برای شناسایی هشدارها است. آزمایش‌های ما همچنین نشان می‌دهد که راه‌حلهایی که تأثیر بازخوردها را در فرآیند یادگیری کاهش می‌دهند (به‌عنوان مثال، طبقه‌بندی‌کننده‌هایی که بازخوردها و نمونه‌های نظارت شده با تأخیر را ترکیب می‌کنند یا طرح‌های وزن‌دهی نمونه را اجرا می‌کنند) اغلب هشدارهای دقیق‌تری را ارائه می‌دهند.

کار آینده مربوط به مطالعه روش‌های تجمع تطبیقی و احتمالاً غیرخطی برای طبقه‌بندی‌کننده‌های آموزش‌دیده بر روی بازخوردها و نمونه‌های نظارت شده با تأخیر است. ما همچنین انتظار داریم که دقت هشدار را با اجرای رویکرد یادگیری برای رتبه‌بندی افزایش دهیم که به طور خاص برای جایگزینی تجمع خطی احتمالات پسین طراحی شده است. در نهایت، یک جهت تحقیقاتی بسیار امیدوارکننده مربوط به روش‌های یادگیری نیمه‌نظارت‌شده برای بهره‌برداری در فرآیند یادگیری است، همچنین چند تراکنش بدون برچسب اخیر.

منابع

[1] A. Dal Pozzolo, G. Boracchi, O. Caelen, C. Alippi, and G. Bontempi, "Credit card fraud detection and concept-drift adaptation with delayed supervised information," in Proc. Int. Joint Conf. Neural Netw., 2015, pp. 1–8